

Análisis Numérico II / Álgebra Lineal Numérica

Clase 05: Sensibilidad de Sistemas Lineales



Facultad de Matemática,
Astronomía, Física y
Computación



Universidad
Nacional
de Córdoba

Introducción: ¿Por qué importa la sensibilidad numérica?

Al resolver un sistema lineal $Ax = b$ mediante una computadora, existen limitaciones inevitables debido a la representación finita de los números.

- El sistema que realmente se termina resolviendo es un sistema perturbado:

$$(A + \Theta)\hat{x} = b + \vartheta$$

donde $\Theta \in \mathbb{R}^{n \times n}$ y $\vartheta \in \mathbb{R}^n$ representan pequeñas perturbaciones producidas por la aritmética de punto flotante de doble precisión.

- Para cuantificar analíticamente cómo estas perturbaciones alteran la solución exacta, es indispensable introducir herramientas matemáticas que midan la magnitud de vectores y matrices: las **normas**.

Definición de Norma

Definición 3.1 (Norma): Una norma en un espacio vectorial X es una función $\| \cdot \| : X \rightarrow \mathbb{R}$ que satisface, para todo $x, y \in X$ y todo escalar $\alpha \in \mathbb{R}$:

1. **Positividad y No Degeneración:**

$$\|x\| \geq 0 \quad y \quad \|x\| = 0 \iff x = 0$$

2. **Propiedad Subaditiva (Desigualdad Triangular):**

$$\|x + y\| \leq \|x\| + \|y\|$$

3. **Homogeneidad Absoluta:**

$$\|\alpha x\| = |\alpha| \|x\|$$

Normas Vectoriales p

Dentro de las normas vectoriales en $\mathbb{R}^n$, las de mayor uso en computación científica son las **normas p** para $p \geq 1$:

- Para un valor finito de $p \in [1, \infty)$:

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

- El caso límite $p = \infty$ (norma de Chebyshev o del máximo):

$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$$

- Casos particulares clásicos: la **norma de Manhattan** ($p = 1$), la **norma Euclídea** ($p = 2$), y la **norma de Chebyshev** ($p = \infty$).

Demostración: Las normas p son normas

Teorema: Si $1 \leq p \leq \infty$, entonces $\|\cdot\|_p$ es una norma vectorial legítima.

Demostración para $p = \infty$:

- **Positividad:** Es evidente que $\|x\|_\infty = \max |x_i| \geq 0$, y es cero si y solo si todos los $x_i = 0$.

- **Homogeneidad:**

$$\|\alpha x\|_\infty = \max_{1 \leq i \leq n} |\alpha x_i| = \max_{1 \leq i \leq n} (|\alpha| |x_i|) = |\alpha| \max_{1 \leq i \leq n} |x_i| = |\alpha| \|x\|_\infty$$

- **Desigualdad Triangular:** Como $|x_i + y_i| \leq |x_i| + |y_i| \leq \|x\|_\infty + \|y\|_\infty$ para todo i :

$$\|x + y\|_\infty = \max_{1 \leq i \leq n} |x_i + y_i| \leq \|x\|_\infty + \|y\|_\infty$$

Demostración para $p \in [1, \infty)$

Las propiedades de positividad, no degeneración y homogeneidad absoluta se heredan directamente de las propiedades del valor absoluto.

Para probar la **desigualdad triangular (Desigualdad de Minkowski)**, recurrimos a la propiedad de convexidad de la función $t \mapsto |t|^p$ para $p \geq 1$:

$$|(1 - \lambda)t_0 + \lambda t_1|^p \leq (1 - \lambda)|t_0|^p + \lambda|t_1|^p \quad \forall \lambda \in [0, 1]$$

Sean $x, y \in \mathbb{R}^n$ vectores no nulos. Definimos:

$$\hat{x} = \frac{x}{\|x\|_p}, \quad \hat{y} = \frac{y}{\|y\|_p}, \quad \lambda = \frac{\|y\|_p}{\|x\|_p + \|y\|_p}$$

De esta manera, $1 - \lambda = \frac{\|x\|_p}{\|x\|_p + \|y\|_p}$.

Demostración para $p \in [1, \infty)$ (Continuación)

Al evaluar la norma del vector normalizado combinado, obtenemos:

$$\left(\frac{\|x + y\|_p}{\|x\|_p + \|y\|_p} \right)^p = \left\| \frac{\|x\|_p}{\|x\|_p + \|y\|_p} \hat{x} + \frac{\|y\|_p}{\|x\|_p + \|y\|_p} \hat{y} \right\|_p^p = \|(1 - \lambda)\hat{x} + \lambda\hat{y}\|_p^p$$

Desglosando en componentes y aplicando la desigualdad de convexidad:

$$\begin{aligned} \|(1 - \lambda)\hat{x} + \lambda\hat{y}\|_p^p &= \sum_{i=1}^n |(1 - \lambda)\hat{x}_i + \lambda\hat{y}_i|^p \\ &\leq \sum_{i=1}^n ((1 - \lambda)|\hat{x}_i|^p + \lambda|\hat{y}_i|^p) = (1 - \lambda)\|\hat{x}\|_p^p + \lambda\|\hat{y}\|_p^p \end{aligned}$$

Dado que $\|\hat{x}\|_p = \|\hat{y}\|_p = 1$, la suma se reduce a $(1 - \lambda) + \lambda = 1$, lo que demuestra que $\|x + y\|_p \leq \|x\|_p + \|y\|_p$. ■

Equivalencia de Normas en $\mathbb{R}^n$

Teorema: Si $||| \cdot |||$ es una norma arbitraria en $\mathbb{R}^n$, entonces existen constantes positivas $\alpha, \beta > 0$ tales que para todo $x \in \mathbb{R}^n$:

$$\alpha \|x\|_2 \leq |||x||| \leq \beta \|x\|_2$$

Demostración (Cota Superior):

Utilizando la desigualdad de Cauchy-Schwarz, es posible acotar la norma 1 por la norma Euclídea:

$$\sum_{i=1}^n |x_i| = \sum_{i=1}^n x_i y_i \leq \|x\|_2 \|y\|_2 = \sqrt{n} \|x\|_2$$

Si expresamos $x = \sum_{i=1}^n x_i e_i$ y definimos $\mu = \max_{1 \leq i \leq n} |||e_i|||$ y $\beta = \sqrt{n}\mu$, por desigualdad triangular obtenemos:

Equivalencia de Normas (Cota Inferior)

$$|||x||| = \left\| \sum_{i=1}^n x_i e_i \right\| \leq \sum_{i=1}^n |x_i| |||e_i||| \leq \mu \sum_{i=1}^n |x_i| \leq \beta \|x\|_2$$

Por la desigualdad triangular reversa e intercalando la cota superior obtenida:

$$|||y||| - |||x||| \leq \|y - x\| \leq \beta \|y - x\|_2$$

Esto demuestra que la función $||| \cdot ||| : \mathbb{R}^n \rightarrow \mathbb{R}$ es **continua** bajo la métrica Euclídea.

Consideremos ahora la esfera unidad Euclídea $S = \{x \in \mathbb{R}^n \mid \|x\|_2 = 1\}$, que es un conjunto cerrado y acotado (compacto). Por el **Teorema de Weierstrass**, la función continua $||| \cdot |||$ alcanza su valor mínimo en un punto $\bar{x} \in S$:

$$\alpha = |||\bar{x}||| > 0 \quad (\text{dado que } \bar{x} \neq 0)$$

Equivalencia de Normas (Conclusión)

Para cualquier $x \neq 0$, el vector normalizado $\frac{x}{\|x\|_2} \in S$, por lo que:

$$\left\| \frac{x}{\|x\|_2} \right\| \geq \alpha \implies \|x\| \geq \alpha \|x\|_2$$

Esto demuestra que toda norma es equivalente a la Euclídea. ■

Corolario 3.7: Si $\|\cdot\|$ y $\|\cdot\|_2$ son dos normas cualesquiera en $\mathbb{R}^n$, existen constantes $\alpha, \beta > 0$ tales que para todo $x \in \mathbb{R}^n$:

$$\alpha \|x\| \leq \|x\|_2 \leq \beta \|x\|$$

El Significado de la Equivalencia de Normas

¿Para qué hacemos esta demostración en Álgebra Lineal Numérica?

Independencia Cualitativa de la Convergencia

En análisis, la equivalencia de normas significa que la convergencia cualitativa de una sucesión no depende de la norma elegida.

Si una sucesión de vectores x^k converge a un vector límite x^* bajo la norma $|\cdot|_a$, entonces se garantiza que converge a x^* bajo cualquier otra norma $|\cdot|_b$ en $\mathbb{R}^n$.

Conceptos topológicos fundamentales (abiertos, cerrados, límites, continuidad de operadores) son los mismos en cualquier norma en dimensión finita.

Conveniencia Matemática en Algoritmos

Demostrar convergencia donde sea más sencillo

En el diseño de algoritmos iterativos (ej. métodos de separación para resolver $Ax = b$), a menudo es mucho más fácil probar la convergencia bajo una norma específica. Los veremos en detalle más adelante.

La garantía: Gracias a la equivalencia, si el error $e^k \rightarrow 0$ en la norma conveniente de la prueba, converge a 0 en todas las demás normas del espacio (como la física o la Euclídea).

La Trampa Numérica: El Efecto de la Dimensión (n)

Aunque todas las normas en $\mathbb{R}^n$ son equivalentes analíticamente, no son equivalentes numéricamente.

Las constantes de equivalencia α y β dependen de n :

$$|x|_2 \leq |x|_1 \leq \sqrt{n}|x|_2 \quad \text{y} \quad |x|_\infty \leq |x|_2 \leq \sqrt{n}|x|_\infty$$

En sistemas grandes: $\sqrt{n} = \sqrt{10^6} = 1000$

Un error de tamaño 1 en norma ∞ podría transformarse en un error de hasta 1000 en norma 2.

Por lo tanto, en precisión finita, la dependencia de n en las cotas puede destruir la estabilidad numérica real.

¿Cómo elegir la norma en la práctica?

Cada norma vectorial se selecciona según el aspecto físico o computacional que se desea controlar:

- Norma Infinito ($\|\cdot\|_\infty$): Excelente para el control del "peor caso" o error máximo admisible en componentes individuales.
- Norma Euclídea ($\|\cdot\|_2$): Representa conceptos físicos directos como la distancia mínima geométrica o la energía del sistema.
- Norma Uno ($\|\cdot\|_1$): Útil para medir la acumulación absoluta de errores o flujos totales en una red de nodos.

Introducción a las Normas Matriciales

Para estudiar el error de sensibilidad en sistemas matriciales, necesitamos extender el concepto de norma al espacio de matrices $\mathbb{R}^{m \times n}$.

Definición: Se dice que una norma matricial $\| \cdot \|$ es **submultiplicativa** si para cualesquiera matrices compatibles A y B se cumple que:

$$\|AB\| \leq \|A\| \|B\|$$

- Esta propiedad es de vital importancia en el análisis de sensibilidad y la convergencia de algoritmos iterativos, ya que nos permite acotar el crecimiento del error en productos matriciales sucesivos.

La Norma de Frobenius

La Norma de Frobenius identifica una matriz $A \in \mathbb{R}^{m \times n}$ con un vector en $\mathbb{R}^{mn}$ a través del operador de vectorización $\text{vec}(A)$ (transforma matriz en un vector de columnas concatenadas):

$$\|A\|_F = \sqrt{\text{tr}(A^T A)} = \left(\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = \|\text{vec}(A)\|_2$$

Propiedades:

1. **Positividad y No Degeneración:** $\|A\|_F \geq 0$, y $\|A\|_F = 0 \iff A = 0$.
2. **Homogeneidad Absoluta:** $\|\alpha A\|_F = |\alpha| \|A\|_F$.
3. **Desigualdad Triangular:** $\|A + B\|_F \leq \|A\|_F + \|B\|_F$.

Demostración: Propiedades

Debido a la linealidad del operador vec (es decir, $\text{vec}(A + \alpha B) = \text{vec}(A) + \alpha \text{vec}(B)$), las propiedades se heredan directamente de la norma vectorial Euclídea:

- **Positividad:** Es claro que $\|\text{vec}(A)\|_2 \geq 0$, y es cero si y solo si todos los componentes de la matriz son nulos.

- **Homogeneidad:**

$$\|\alpha A\|_F = \|\text{vec}(\alpha A)\|_2 = \|\alpha \text{vec}(A)\|_2 = |\alpha| \|\text{vec}(A)\|_2 = |\alpha| \|A\|_F$$

- **Desigualdad Triangular:**

$$\begin{aligned} \|A + B\|_F &= \|\text{vec}(A + B)\|_2 = \|\text{vec}(A) + \text{vec}(B)\|_2 \\ &\leq \|\text{vec}(A)\|_2 + \|\text{vec}(B)\|_2 = \|A\|_F + \|B\|_F \end{aligned}$$

Demostración: Submultiplicatividad

Queremos probar que para matrices compatibles $A \in \mathbb{R}^{m \times n}$ y $B \in \mathbb{R}^{n \times p}$ se cumple $\|AB\|_F \leq \|A\|_F \|B\|_F$.

Sean $a_i \in \mathbb{R}^n$ (las columnas de A^T , es decir, las filas de A) y $b_j \in \mathbb{R}^n$ (las columnas de B). Los elementos del producto $C = AB$ son $c_{ij} = (a_i)^T b_j$. Aplicando Cauchy-Schwarz:

$$\begin{aligned}\|AB\|_F^2 &= \sum_{i=1}^m \sum_{j=1}^p |(a_i)^T b_j|^2 \leq \sum_{i=1}^m \sum_{j=1}^p \|a_i\|_2^2 \|b_j\|_2^2 \\ \|AB\|_F^2 &\leq \left(\sum_{i=1}^m \|a_i\|_2^2 \right) \left(\sum_{j=1}^p \|b_j\|_2^2 \right) = \|A\|_F^2 \|B\|_F^2 \\ &\implies \|AB\|_F \leq \|A\|_F \|B\|_F\end{aligned}$$

Radio Espectral y Normas Inducidas

Definición (Radio Espectral): Para una matriz cuadrada $A \in \mathbb{R}^{n \times n}$, el radio espectral $\rho(A)$ es el valor máximo de los módulos de sus autovalores $\lambda \in \mathbb{C}$:

$$\rho(A) = \max\{|\lambda| \mid \det(A - \lambda I) = 0\}$$

Definición (Norma Inducida): Una norma vectorial induce una norma matricial que mide la amplificación máxima de un vector:

$$\|A\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|$$

Toda norma matricial inducida es submultiplicativa por construcción:

$$\|AB\| \leq \|A\| \|B\|$$

Cálculo de Normas Inducidas Clásicas

Para cualquier matriz $A \in \mathbb{R}^{m \times n}$, tenemos:

1. Norma-1 (Máxima suma absoluta por columnas):

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

2. Norma-Infinito (Máxima suma absoluta por filas):

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

3. Norma-2 (Norma Espectral):

$$\|A\|_2 = \sqrt{\rho(A^T A)}$$

Demostración: Fórmula de la Norma-1

Queremos probar que $\|A\|_1 = \max_j \sum_{i=1}^m |a_{ij}|$.

- **Cota Superior:** Para cualquier $x \in \mathbb{R}^n$, expandiendo $\|Ax\|_1$:

$$\|Ax\|_1 = \sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{j=1}^n |x_j| \sum_{i=1}^m |a_{ij}| \leq \left(\max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \right) \|x\|_1$$

Dividiendo por $\|x\|_1$ y tomando el supremo para $x \neq 0$, se obtiene

$$\|A\|_1 \leq \max_j \sum_{i=1}^m |a_{ij}|.$$

- **Cota Inferior:** Sea l la columna donde se alcanza el máximo. Evaluando en el vector canónico e_l (que tiene $\|e_l\|_1 = 1$):

$$\|A\|_1 \geq \|Ae_l\|_1 = \sum_{i=1}^m |a_{il}| = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \quad \blacksquare$$

Demostración: Fórmula de la Norma-Infinito

Queremos probar que $\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$.

- **Cota Superior:** Para cualquier $x \in \mathbb{R}^n$, expandiendo $\|Ax\|_\infty$:

$$\|Ax\|_\infty = \max_{1 \leq i \leq m} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| |x_j| \leq \left(\max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \right) \|x\|_\infty$$

Por lo tanto, al dividir por $\|x\|_\infty$, se obtiene $\|A\|_\infty \leq \max_i \sum_{j=1}^n |a_{ij}|$.

- **Cota Inferior:** Sea l la fila que maximiza la suma. Definimos $\hat{x}$ tal que $\hat{x}_j = 1$ si $a_{lj} \geq 0$ y $\hat{x}_j = -1$ si $a_{lj} < 0$. Como $\|\hat{x}\|_\infty = 1$:

$$\|A\hat{x}\|_\infty = \max_i \left| \sum_{j=1}^n a_{ij} \hat{x}_j \right| \geq \left| \sum_{j=1}^n a_{lj} \hat{x}_j \right| = \sum_{j=1}^n |a_{lj}| = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \quad \blacksquare$$

Demostración: Fórmula de la Norma-2 (Espectral)

Queremos probar que $\|A\|_2^2 = \rho(A^T A)$.

El cuadrado de la norma inducida es la solución del problema de optimización:

$$\|A\|_2^2 = \max_{\|x\|_2=1} \|Ax\|_2^2 \quad \text{sujeto a} \quad h(x) = \|x\|_2^2 - 1 = 0$$

Definiendo la lagrangiana $f(x) = -\|Ax\|_2^2$ y aplicando multiplicadores de Lagrange:

$$\nabla f(x) + \bar{\lambda} \nabla h(x) = 0 \implies -2A^T Ax + 2\bar{\lambda}x = 0 \implies A^T Ax = \bar{\lambda}x$$

Por lo tanto, el vector que alcanza el óptimo es un autovector de $A^T A$. Evaluando la forma cuadrática para un autovector normalizado v asociado al autovalor λ :

$$\|Av\|_2^2 = v^T A^T Av = v^T (\lambda v) = \lambda \leq \rho(A^T A) \implies \|A\|_2^2 = \rho(A^T A) \quad \blacksquare$$

Número de Condición $\kappa(A)$

Definición: Para una matriz no singular $A \in \mathbb{R}^{n \times n}$, su **número de condición** es:

$$\kappa(A) = \|A\| \|A^{-1}\|$$

Interpretación Geométrica

Como $\|A^{-1}\| = 1 / \min_{\|x\|=1} \|Ax\|$, el número de condición mide la relación entre la distorsión máxima y mínima de la esfera unidad bajo A :

$$\kappa(A) = \frac{\max_{\|x\|=1} \|Ax\|}{\min_{\|x\|=1} \|Ax\|}$$

- **En Norma-2:** Se calcula usando los autovalores extremos de $A^T A$:

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}} = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}}$$

Ejemplo Numérico de Mal Condicionamiento

Considere la matriz $A \in \mathbb{R}^{2 \times 2}$ y su inversa:

$$A = \begin{bmatrix} 1000 & 999 \\ 999 & 998 \end{bmatrix}, \quad A^{-1} = \begin{bmatrix} -998 & 999 \\ 999 & -1000 \end{bmatrix}$$

En norma infinito: $\|A\|_{\infty} = 1999$ y $\|A^{-1}\|_{\infty} = 1999$.

Por lo tanto, el número de condición es extremadamente alto:

$$\kappa_{\infty}(A) = 1999 \times 1999 = 3,996,001$$

Consecuencia:

- El vector $x = [1, 1]^T$ es la dirección de máxima magnificación:
 $\|Ax\|_{\infty} = 1999 = \|A\|_{\infty}$.
- Un cambio infinitesimal en la dirección de mínima magnificación alterará drásticamente la solución.

Sensibilidad de Sistemas Lineales

Teorema (Perturbación en el término independiente b): Sea $A \in \mathbb{R}^{n \times n}$ no singular y $b \neq 0$. Si $A\bar{x} = b$ y $A\hat{x} = b + \vartheta$, entonces:

$$\frac{\|\hat{x} - \bar{x}\|}{\|\bar{x}\|} \leq \kappa(A) \frac{\|\vartheta\|}{\|b\|}$$

Demostración:

Definiendo el error $\zeta = \hat{x} - \bar{x}$, restamos las ecuaciones y obtenemos $A\zeta = \vartheta \implies \zeta = A^{-1}\vartheta$. Tomando norma:

$$\|\zeta\| \leq \|A^{-1}\| \|\vartheta\|$$

Por otro lado, como $b = A\bar{x}$, se cumple que $\|b\| \leq \|A\| \|\bar{x}\|$, lo que equivale a $\frac{1}{\|\bar{x}\|} \leq \frac{\|A\|}{\|b\|}$. Combinando ambas desigualdades:

$$\|\zeta\| \leq \|A\| \|\bar{x}\| \frac{\|\vartheta\|}{\|b\|}$$

Invertibilidad Bajo Perturbaciones

Para analizar perturbaciones en la matriz del sistema, primero se requiere acotar la perturbación sobre la matriz identidad:

Lema: Si $F \in \mathbb{R}^{n \times n}$ cumple que $\|F\| < 1$, entonces $I - F$ es no singular y:

$$(I - F)^{-1} = \sum_{k=0}^{\infty} F^k, \quad \text{con} \quad \|(I - F)^{-1}\| \leq \frac{1}{1 - \|F\|}$$

Esto nos permite analizar matrices arbitrarias no singulares bajo una perturbación Θ :

Teorema: Si A es no singular y $\|A^{-1}\Theta\| < 1$, entonces $A + \Theta$ es no singular, cumpliéndose:

$$\|(A + \Theta)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\Theta\|}$$

Perturbaciones Simultáneas en A y b

Teorema: Sea $A \in \mathbb{R}^{n \times n}$ no singular, $b \neq 0$ y $\|A^{-1}\Theta\| < 1$. Si $A\bar{x} = b$ y $(A + \Theta)\hat{x} = b + \vartheta$, entonces el error relativo está acotado por:

$$\frac{\|\hat{x} - \bar{x}\|}{\|\bar{x}\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\Theta\|}{\|A\|}} \left(\frac{\|\Theta\|}{\|A\|} + \frac{\|\vartheta\|}{\|b\|} \right)$$

Significado del Denominador:

El término $1 - \kappa(A) \frac{\|\Theta\|}{\|A\|}$ en el denominador actúa como un factor de seguridad. Si la perturbación sobre la matriz Θ es lo suficientemente grande como para acercar la matriz a la singularidad, el denominador tiende a cero, haciendo que la cota de error crezca indefinidamente.

Demostración

Sea el error de la solución $\zeta = \hat{x} - \bar{x}$. Sustituyendo y operando en el sistema perturbado:

$$(A + \Theta)(\bar{x} + \zeta) = b + \vartheta \implies A\zeta = \vartheta - \Theta\bar{x} - \Theta\zeta \implies \zeta = A^{-1}(\vartheta - \Theta\bar{x} - \Theta\zeta)$$

Tomando normas y aplicando la desigualdad triangular:

$$\|\zeta\| \leq \|A^{-1}\| (\|\vartheta\| + \|\Theta\|\|\bar{x}\| + \|\Theta\|\|\zeta\|)$$

Agrupando los términos con $\|\zeta\|$ a la izquierda de la desigualdad:

$$(1 - \|A^{-1}\|\|\Theta\|)\|\zeta\| \leq \|A^{-1}\| (\|\Theta\|\|\bar{x}\| + \|\vartheta\|)$$

Dividiendo por $\|\bar{x}\|$ e introduciendo el término $\|A\|$ de manera conveniente:

$$\left(1 - \kappa(A) \frac{\|\Theta\|}{\|A\|}\right) \frac{\|\zeta\|}{\|\bar{x}\|} \leq \kappa(A) \left(\frac{\|\Theta\|}{\|A\|} + \frac{\|\vartheta\|}{\|A\|\|\bar{x}\|}\right)$$