

Análisis Numérico II / Álgebra Lineal Numérica

Clase 07: Descomposición QR



Facultad de Matemática,
Astronomía, Física y
Computación



Universidad
Nacional
de Córdoba

Algoritmo (Reflexión de Householder)

Entrada: $x \in \mathbb{R}^m$. Salidas: $u \in \mathbb{R}^m$, $\rho \in \mathbb{R}$ tal que $I - \rho uu^T x = \sigma e_1$

- Definir $\sigma = \sum_{i=2}^m x_i^2$
- Si $\sigma = 0$, retornar $u = 0$, $\rho = 0$
- Definir $\mu = \sqrt{\sigma + x_1^2}$
- Si $x_1 \leq 0$, definir $\gamma = x_1 - \mu$, sino definir $\gamma = -\sigma/(x_1 + \mu)$
- Definir $\rho = 2\gamma^2/(\sigma + \gamma^2)$
- Retornar $u = [1, \quad x_2/\gamma, \quad \dots, \quad x_m/\gamma]^T$ y ρ

Algoritmo (Desc. QR por Refl. de Householder)

Entrada: $A \in \mathbb{R}^{m \times n}$. **Salidas:** $Q \in \mathbb{R}^{m \times m}$ ortogonal, $R \in \mathbb{R}^{m \times n}$ triangular superior

- Definir $Q = I$, $p = \min(m, n)$
- Para $j = 1 \dots p$, definir $\mathcal{I} = \{j, \dots, m\}$, $\mathcal{J} = \{j, \dots, n\}$
 - $u, \rho = \text{Householder}(A_{\mathcal{I},j})$
 - $w = \rho u$
 - $A_{\mathcal{I},\mathcal{J}} \leftarrow A_{\mathcal{I},\mathcal{J}} - w(u^T A_{\mathcal{I},\mathcal{J}})$
 - $Q_{\mathcal{I},*} \leftarrow Q_{*,\mathcal{I}} - (Q_{*,\mathcal{I}}w)u^T$
- Retornar: $Q, R = A$

Implementación Práctica

- Dónde se metió P ? 🙄
- Formar explícitamente la matriz de Householder requiere $O(m^2)$ de memoria y $O(m^2n)$ de operaciones inútiles.

- Explotamos que es una matriz de rango 1 para aplicarla directamente sobre A :

$$PA = (I - \beta vv^T)A = A - \beta v(v^T A)$$

- Este procedimiento reduce el costo a $2mn$ **flops** por aplicación de reflector.

Conteo Operacional (Crear R)

Sumamos el costo de las actualizaciones de rango 1 en cada paso k de dimensión decreciente $m' = m - k + 1$ y $n' = n - k + 1$:

- Multiplicación vector-matriz ($w^T = v^T A'$): $\approx 2m'n'$ flops.
- Actualización de rango 1 ($A' - \beta v w^T$): $\approx 2m'n'$ flops.
- Costo total por paso k : $\approx 4(m - k + 1)(n - k + 1)$ flops.

Sumando desde $k = 1$ hasta n , obtenemos el costo $2mn^2 - \frac{2}{3}n^3$ flops.

- Si $m = n$, el costo es de $\frac{4}{3}n^3$ flops.
- Si $m \gg n$, el término $2mn^2$ domina, con un costo aproximado de $2mn^2$ flops.

Algo para notar sobre Q

- En el algoritmo estamos construyendo Q , pero en realidad no necesitamos construirla.
- En su lugar, guardamos el vector de Householder u_k dentro de las posiciones que se acaban de anular por debajo de la diagonal (*pierdo información?*).
- El escalar ρ_k se guarda de forma paralela en un vector auxiliar de tamaño n .
- Si necesitamos multiplicar por Q^T , aplicamos la secuencia de actualizaciones:

$$Q^T b = (Q_n \cdots Q_2 Q_1) b$$

Householder vs. Givens: ¿Cuándo usar cuál?

Característica	 Householder (<i>El Martillo</i>)	 Givens (<i>El Bisturí</i>)
Acción	Anula toda una subcolumna en un solo paso.	Anula un único elemento a la vez (afecta 2 filas).
Geometría	Reflexión respecto a un hiperplano.	Rotación plana en 2D.
Uso Ideal	Matrices densas (más rápido y estable).	Matrices dispersas , en banda o estructuradas.

Teorema (Forma Reducida de QR):

Si $A = QR$ es la descomposición QR de $A \in \mathbb{R}^{m \times n}$ de rango n y $A = [a^1 \ \dots \ a^n]$, $Q = [q^1 \ \dots \ q^m]$, entonces

$$\text{span}\{a^1, \dots, a^k\} = \text{span}\{q^1, \dots, q^k\}$$

para $k = 1, \dots, n$. En particular, si $Q = [Q_1 \ Q_2]$ donde $Q_1 \in \mathbb{R}^{m \times n}$ y $Q_2 \in \mathbb{R}^{m \times (m-n)}$, entonces $A = Q_1 R_1$ donde $R_1 \in \mathbb{R}^{n \times n}$ y $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$.

Demostración:

Comparando columnas se obtiene que si $1 \leq j \leq n$, entonces:

$$a^j = Qr^j = [q^1 \quad \dots \quad q^n] \begin{bmatrix} r_{1j} \\ \vdots \\ r_{jj} \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sum_{i=1}^j r_{ij} q^i \in \text{span}\{q^1, \dots, q^j\}$$

luego $\text{span}\{a^1, \dots, a^n\} \subseteq \text{span}\{q^1, \dots, q^n\}$. Como A tiene rango n , entonces $q^1, \dots, q^n$ son linealmente independientes, por lo tanto

$$\text{span}\{a^1, \dots, a^n\} = \text{span}\{q^1, \dots, q^n\}$$

Demostración (continuación):

Por otro lado,

$$A = QR = [Q_1 \quad Q_2] \begin{bmatrix} R_1 \\ 0 \end{bmatrix} = Q_1 R_1$$

y luego $Im(A) = Im(Q_1)$. ■

Se dice que $A = Q_1 R_1$ es la **Descomposición QR Reducida** de A . Bajo ciertas hipótesis es única.

Teorema

Sea $A \in \mathbb{R}^{m \times n}$ de rango n . Entonces la descomposición QR reducida $A = Q_1 R_1$ es única si Q_1 tiene columnas ortonormales y R_1 tiene diagonal estrictamente positiva. Más aún, R_1 es el factor de Cholesky de $A^T A$.

Demostración:

Como $A = Q_1 R_1$ con columnas ortonormales y R_1 triangular superior con diagonal positiva, entonces

$$A^T A = R_1^T Q_1^T Q_1 R_1 = R_1^T R_1$$

Como R_1 es triangular superior con diagonal positiva, es el factor de Cholesky de $A^T A$. Además, $Q_1 = A R_1^{-1}$ también es única. ■

Entonces, cómo resolvemos Cuadrados Mínimos?

Realizamos la descomposición QR de $A \in \mathbb{R}^{m \times n}$. Si A es de rango n , entonces:

$$Q^T A = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \quad y \quad Q^T b = \begin{bmatrix} Q_1^T b \\ Q_2^T b \end{bmatrix} = \begin{bmatrix} c \\ d \end{bmatrix}$$

donde $R_1 \in \mathbb{R}^{n \times n}$ es triangular superior con diagonal estrictamente positiva, $c \in \mathbb{R}^n$ y $d \in \mathbb{R}^{m-n}$. Entonces,

$$\begin{aligned} \min_x \|Ax - b\|_2^2 &= \min_x \|Q^T(Ax - b)\|_2^2 = \\ &= \min_x \left\| \begin{bmatrix} R_1 \\ 0 \end{bmatrix} x - \begin{bmatrix} c \\ d \end{bmatrix} \right\|_2^2 = \min_x \|R_1 x - c\|_2^2 + \|d\|_2^2 \end{aligned}$$

Finalmente, si $R\hat{x} = c$, entonces $\hat{x}$ resuelve el problema de cuadrados mínimos y $\min_x \|Ax - b\|_2^2 = \|d\|_2^2$. :D

Algoritmo (Cuadrados Mínimos por QR)

Entrada: $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. **Salidas:** $x \in \mathbb{R}^n$ y residuo mínimo $r_2 = \|Ax - b\|_2$.

- $Q, R = \text{descomposicion_QR}(A)$
- $q = Q^T b$
- Definir $p = \max\{i : r_{ii} \neq 0\}$
- Definir $\mathcal{I} = \{1, \dots, p\}$, $\mathcal{J} = \{1, \dots, n\} - \mathcal{I}$
- $y_{\mathcal{I}} = \text{sol_trsups}(R_{\mathcal{I}, \mathcal{I}}, q_{\mathcal{I}})$ y definir $x = \begin{bmatrix} y_{\mathcal{I}} \\ 0 \end{bmatrix}$

Retornar: x y $r_2 = \|q_{\mathcal{J}}\|_2$

Teorema (Estabilidad de Givens y Householder)

Cuando la factorización QR se calcula utilizando una secuencia de transformaciones de Householder o Givens en aritmética de punto flotante, los factores calculados $\hat{Q}$ y $\hat{R}$ son los factores ortogonal y triangular superior exactos para una matriz ligeramente perturbada $A + \delta A$. El tamaño de la perturbación es pequeño y está acotado por:

$$\frac{|\delta A|}{|A|} = O(\epsilon_{\text{maquina}}).$$



LU vs. QR

Característica	Descomposición LU	Descomposición QR
Caso de uso	Sistemas cuadrados: $Ax = b$	Mínimos cuadrados: $Ax \approx b$
Aplicabilidad	Matriz A cuadrada.	Matriz $A \in \mathbb{R}^{m \times n}$ de rango de columnas completo.
Estabilidad numérica	Inestable sin pivoteo, pero hay casos patológicos	Inherentemente estable (matrices ortogonales)
Costo computacional	$\frac{2}{3}n^3$ flops.	$\frac{4}{3}n^3$ flops.

Acaso hay algo mejor que QR? ❤️

- Es más estable y permite "solucionar" sistemas lineales de dimensión $m \times n$
- Tenemos una sola contra: necesitamos tener $\text{rank}(A) = n$. Esto se puede llegar a evitar intercambiando columnas pero nadie lo hace...
- Existe una descomposición que permite resolver cuadrados mínimos con matrices singulares y es uno de los mayores descubrimientos del álgebra lineal numérica, la ciencia de datos y el machine learning.
- Igualmente no nos olvidemos de QR, la vamos a volver a ver más adelante.