

Análisis Numérico II / Álgebra Lineal Numérica

Clase 09: Descomposición SVD




Facultad de Matemática,
Astronomía, Física y
Computación



Universidad
Nacional
de Córdoba

Los 4 Subespacios Fundamentales

Toda matriz $A \in \mathbb{R}^{m \times n}$ define una transformación lineal entre dos espacios vectoriales fundamentales: el **dominio de entrada** $\mathbb{R}^n$ y el **codominio de salida** $\mathbb{R}^m$.



1. El Espacio Columna (Rango-Imagen): $R(A)$

Es el conjunto de todos los vectores de salida posibles que pueden generarse mediante la transformación lineal de un vector de entrada.

- **Definición Formal:**

$$R(A) = \{y \in \mathbb{R}^m \mid \exists x \in \mathbb{R}^n : y = Ax\}$$

- **Geometría:** Es el **generado (span)** de las columnas de A . Es un subespacio del espacio de salida $\mathbb{R}^m$.
- **Dimensión:** Su dimensión se define como el **rango (r)** de la matriz, que representa el número de columnas linealmente independientes.

2. El Espacio Nulo (Núcleo): $N(A)$

Es el conjunto de todos los vectores del dominio de entrada que son proyectados exactamente hacia el vector nulo mediante la transformación lineal.

- **Definición Formal:**

$$N(A) = \{x \in \mathbb{R}^n \mid Ax = 0\}$$

- **Geometría:** Es un subespacio del espacio de entrada $\mathbb{R}^n$.
- **Significado Numérico:** Si el espacio nulo contiene elementos más allá del vector cero (0), la transformación deja de ser inyectiva.
- **Dimensión:** Su dimensión se conoce como **nulidad** ($n - r$).

3. El Espacio Fila: $R(A^T)$

Es el conjunto de todas las combinaciones lineales posibles formadas a partir de los vectores fila de la matriz A .

- **Definición Formal:** Es equivalente al espacio columna de la matriz transpuesta:

$$R(A^T) = \{x \in \mathbb{R}^n \mid \exists y \in \mathbb{R}^m : x = A^T y\}$$

- **Geometría:** Es un subespacio del espacio de entrada $\mathbb{R}^n$.
- **Igualdad Fundamental:** La dimensión del espacio fila es exactamente igual al **rango** (r) de la matriz. Toda matriz posee el mismo número de filas linealmente independientes que de columnas linealmente independientes.

4. El Espacio Nulo Izquierdo: $N(A^T)$

Es el espacio nulo asociado a la matriz transpuesta de la transformación lineal.

- **Definición Formal:**

$$N(A^T) = \{y \in \mathbb{R}^m \mid A^T y = 0\}$$

- **Denominación:** Se denomina "izquierdo" porque al transponer la igualdad se reescribe como $y^T A = 0^T$, mostrando que los vectores fila actúan multiplicando a la matriz A por izquierda.
- **Geometría:** Subespacio del espacio de salida $\mathbb{R}^m$ con dimensión igual a $m - r$.

Agrupemos estos Subespacios

- Subespacios de Entrada: $R(A^T)$ y $N(A)$
- Subespacios de Salida: $R(A)$ y $N(A^T)$
- Estos espacios son ortogonales entre sí y el teorema de la suma de dimensiones nos dice que:

$$\dim(R(A^T)) + \dim(N(A)) = r + (n - r) = n$$

$$\dim(R(A)) + \dim(N(A^T)) = r + (m - r) = m$$

Por lo tanto, podemos escribir las bases ortonormales de $\mathbb{R}^n$ y $\mathbb{R}^m$ como:

$$\mathbb{R}^n = R(A^T) \oplus N(A) \quad \text{y} \quad \mathbb{R}^m = R(A) \oplus N(A^T)$$

Matrices Ortogonales y Bases

- Lo visto anteriormente nos permite concluir que podemos escribir las bases ortonormales de $\mathbb{R}^n$ y $\mathbb{R}^m$ como:

$$\begin{aligned}\mathbb{R}^n &= \text{span}\{v_1, \dots, v_r\} \oplus \text{span}\{v_{r+1}, \dots, v_n\} \\ \mathbb{R}^m &= \text{span}\{u_1, \dots, u_r\} \oplus \text{span}\{u_{r+1}, \dots, u_m\}\end{aligned}$$

De esta forma podemos escribir a la matriz A como:

$$A = U\Sigma V^T,$$

donde $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ son matrices ortogonales. Qué pinta tiene la matriz Σ ? Busquemos esa información en AA^T y $A^T A$.

De dónde sale Σ ?

- $A^T A$ es una matriz simétrica real de tamaño $n \times n$.
- AA^T es una matriz simétrica real de tamaño $m \times m$.
- Entonces, podemos escribir a $A^T A$ y AA^T como:

$$A^T A = V \Sigma^T \Sigma V^T \quad \text{y} \quad AA^T = U \Sigma \Sigma^T U^T,$$

que son diagonalizaciones por autovalores!

- De esta forma, las matrices $\Sigma^T \Sigma$ y $\Sigma \Sigma^T$ son diagonales.

Valores Singulares

Definición: Dada $A \in \mathbb{R}^{m \times n}$ de rango r , llamamos **valores singulares** de A a las raíces cuadradas de los autovalores de $A^T A$ (o de AA^T).

Nota: Como el rango de una matriz y su transpuesta son iguales, entonces A^T y A tienen los mismos valores singulares no nulos (hay que completar ceros hasta llegar a m y n en Σ)

Teorema (Descomposición en Valores Singulares)

Toda matriz real $A \in \mathbb{R}^{m \times n}$ de rango r puede descomponerse en un producto:

$$A = U\Sigma V^T$$

Donde:

- $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ son ortogonales.
- $\Sigma \in \mathbb{R}^{m \times n}$ es una matriz diagonal de estructura rectangular con valores singulares $\sigma_1 \geq \dots \geq \sigma_r > 0$ y $\sigma_{r+1} = \dots = \sigma_{\min(m,n)} = 0$.

$$\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{bmatrix}$$

Demostración

La existencia de la SVD para cualquier matriz real $A \in \mathbb{R}^{m \times n}$ puede probarse de forma constructiva diagonalizando una matriz simétrica extendida.

Definimos la matriz simétrica en bloques $B \in \mathbb{R}^{(m+n) \times (m+n)}$:

$$B = \begin{bmatrix} 0 & A \\ A^T & 0 \end{bmatrix}$$

Como B es simétrica real, es **ortogonalmente diagonalizable**:

$$B = Q\Lambda Q^T$$

donde Λ es la matriz diagonal con los autovalores de B , y Q es una matriz ortogonal formada por sus autovectores.

Demostración (continuación)

Consideremos un autovector $\begin{bmatrix} x \\ y \end{bmatrix}$ de B correspondiente a un autovalor no nulo λ :

$$B \begin{bmatrix} x \\ y \end{bmatrix} = \lambda \begin{bmatrix} x \\ y \end{bmatrix} \implies \begin{aligned} Ay &= \lambda x \\ A^T x &= \lambda y \end{aligned}$$

Aplicando A^T a la primera ecuación y A a la segunda:

$$\begin{aligned} A^T Ay &= \lambda(A^T x) = \lambda(\lambda y) = \lambda^2 y \\ AA^T x &= \lambda(Ay) = \lambda(\lambda x) = \lambda^2 x \end{aligned}$$

- **Conclusión:** λ^2 es autovalor común de $A^T A$ y AA^T .
- Los **valores singulares** σ_i son las raíces cuadradas positivas: $\sigma_i = \sqrt{\lambda_i^2} = |\lambda_i|$.
- Además, se puede verificar que $\begin{bmatrix} x \\ -y \end{bmatrix}$ es autovector para el autovalor $-\lambda$.

Demostración (final)

Sean X la matriz de autovectores de AA^T y Y la matriz de autovectores de $A^T A$ (asociados a $\lambda^2 \neq 0$). Podemos estructurar Q y Λ como:

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} X & X \\ Y & -Y \end{bmatrix}, \quad \Lambda = \begin{bmatrix} \Sigma & 0 \\ 0 & -\Sigma \end{bmatrix}$$

Sustituyendo Q y Λ en la relación $B = Q\Lambda Q^T$, al operar por bloques recuperamos:

$$A = X\Sigma Y^T$$

Identificando las matrices ortogonales $U = X$ y $V = Y$, queda establecida la SVD:

$$A = U\Sigma V^T \quad \blacksquare$$

Proposición

Sea $A \in \mathbb{R}^{m \times n}$ de rango r y $A = U\Sigma V^T$ su descomposición SVD, entonces:

1. $\|A\|_2 = \sigma_1$
2. $\|A\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_r^2}$

Demostración: $\|A\|_2 = \sigma_1$

Como $\|\Sigma\|_2 = \sigma_1$ y la norma 2 es invariante por transformaciones ortogonales:

$$\|A\|_2 = \|U^T A V\|_2 = \|\Sigma\|_2 = \sigma_1$$

Demostración: $\|A\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_r^2}$

Escribimos la matriz Σ en bloques:

$$\Sigma = \begin{bmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{bmatrix} \quad \text{con} \quad \hat{\Sigma} = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$

Usando la propiedad cíclica de la traza, $\text{tr}(M_1 M_2) = \text{tr}(M_2 M_1)$:

$$\begin{aligned} \|A\|_F^2 &= \text{tr}(A^T A) = \text{tr}(V \Sigma^T U^T U \Sigma V^T) = \text{tr}(V \Sigma^T \Sigma V^T) \\ &= \text{tr}(\Sigma^T \Sigma V^T V) = \text{tr}(\Sigma^T \Sigma) = \text{tr}(\hat{\Sigma}^T \hat{\Sigma}) = \sigma_1^2 + \cdots + \sigma_r^2 \end{aligned}$$


Tomando raíz cuadrada, obtenemos:

$$\|A\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_r^2} \quad \blacksquare$$

La Anatomía de una Transformación: Intuición de la SVD ($A = U\Sigma V^T$)

Explicar visualmente cómo la Descomposición en Valores Singulares (SVD) descompone cualquier transformación lineal en tres etapas geométricas claras.


DOMINIO ORIGINAL



Círculo Original / Esfera Unidad

La SVD mapea una esfera perfecta en el dominio hacia un elipsoide en el codominio.


Paso 1: Rotación en el Dominio (V^T)



Alinea los ejes principales con las direcciones de estiramiento sin cambiar longitudes.

Componente V^T :
Ortogonal/Ortonormal.
Rotación o reflexión inicial
(Cambio de base).


Paso 2: Escalamiento Crítico (Σ)



Los valores singulares σ_i dilatan o contraen el espacio en los nuevos ejes.

Componente Σ : Diagonal
($\sigma_i \geq 0$). Estiramiento o compresión (Scaling).


Paso 3: Rotación en el Codominio (U)



Ubica el espacio escalado en su orientación final según la base ortonormal de salida.

Componente U :
Ortogonal/Ortonormal.
Rotación o reflexión final
hacia el destino.

DESTINO FINAL: ELIPSOIDE



Anatomía del Elipsoide Final

Los semiejes corresponden exactamente a los vectores $\sigma_1 \mathbf{u}_1$ y $\sigma_2 \mathbf{u}_2$.

El Teorema SVD: $A = U\Sigma V^T$

Cualquier matriz A se descompone en matrices ortogonales U , V y una diagonal Σ .

Contexto de la SVD

La SVD es el "cuchillo suizo" del álgebra lineal. Permite entender una matriz A no solo como una tabla de números, sino como una secuencia de rotaciones y estiramientos que deforman el espacio de manera predecible, transformando una esfera unidad en un elipsoide.

A como suma de matrices de rango 1

Tenemos que, si $A \in \mathbb{R}^{m \times n}$ tiene rango r :

$$A = U\Sigma V^T = \begin{bmatrix} u^1 & \dots & u^m \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{bmatrix} \begin{bmatrix} (v^1)^T & \dots & (v^n)^T \end{bmatrix} = \sum_{i=1}^r \sigma_i u^i (v^i)^T$$

Observación: Para aproximar la matriz A con una matriz de menor rango, podemos simplemente sumar los primeros k términos de la descomposición, con $k < r$. Qué tan buena aproximación es?

Teorema (Eckart-Young)

Sea $A \in \mathbb{R}^{m \times n}$ de rango r y $A = U\Sigma V^T$ su descomposición SVD. Para cualquier $k \in \{1, \dots, r\}$ podemos escribir:

$$A_k = \sum_{i=1}^k \sigma_i u^i (v^i)^T.$$

Entonces:

- A_k tiene rango k y
- $\min\{\|A - B\|_2 \mid B \in \mathbb{R}^{m \times n} \text{ de rango } k\} = \|A - A_k\|_2 = \sigma_{k+1}.$

Esto quiere decir que A_k es la mejor aproximación de rango k de la matriz A en términos de la norma 2.

Demostración - Rango de A_k

Como $(v^i)^T v^j = 0$ si $i \neq j$ e igual a 1 si $i = j$, multiplicando por U^T y V :

$$U^T A_k V = \begin{bmatrix} (u^1)^T \\ \vdots \\ (u^m)^T \end{bmatrix} [\sigma_1 u^1 \quad \dots \quad \sigma_k u^k \quad 0 \quad \dots \quad 0] = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix}$$

donde:

$$\Sigma_k = \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_k \end{bmatrix}$$

Luego, concluimos que $\text{ext}\{\text{rango}\}(A_k) = k$.

Demostración - Cota Inferior del Error

Sea $B \in \mathbb{R}^{m \times n}$ una matriz arbitraria con $\text{rango}(B) \leq k$. Por el teorema de la dimensión, $\dim(\text{Ker}(B)) \geq n - k$. Luego:

$$\dim(\text{Ker}(B)) + \dim(\text{span}\{v^1, \dots, v^{k+1}\}) \geq (n - k) + (k + 1) = n + 1$$

Esto garantiza la existencia de un vector unitario $z \in \text{Ker}(B) \cap \text{span}\{v^1, \dots, v^{k+1}\}$ con $\|z\|_2 = 1$. Entonces:

$$1 = \|z\|_2^2 = \|V^T z\|_2^2 = \sum_{i=1}^{k+1} ((v^i)^T z)^2$$

pues $(v^i)^T z = 0$ si $i > k + 1$.

Demostración - Cota Inferior (cont.)

Usando que $Bz = 0$, calculamos la norma del error $\|B - A\|_2^2$:

$$\begin{aligned}\|B - A\|_2^2 &\geq \|(B - A)z\|_2^2 = \|Az\|_2^2 = \|U\Sigma V^T z\|_2^2 = \|\Sigma V^T z\|_2^2 \\ &= \sum_{i=1}^{k+1} \sigma_i^2 ((v^i)^T z)^2 \geq \sigma_{k+1}^2 \sum_{i=1}^{k+1} ((v^i)^T z)^2 = \sigma_{k+1}^2\end{aligned}$$

Por lo tanto, para cualquier matriz B de rango $\leq k$:

$$\|B - A\|_2 \geq \sigma_{k+1}$$

Demostración - La cota se alcanza en A_k

Veamos que la cota inferior se alcanza exactamente si $B = A_k$.

$$U^T(A_k - A)V = U^T A_k V - U^T A V = \begin{bmatrix} 0 & 0 & 0 \\ 0 & -\tilde{\Sigma}_k & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

donde:

$$\tilde{\Sigma}_k = \begin{bmatrix} \sigma_{k+1} & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$

Como la norma 2 es invariante por transformaciones ortogonales:

$$\|A_k - A\|_2 = \|U^T(A_k - A)V\|_2 = \|\tilde{\Sigma}_k\|_2 = \sigma_{k+1} \quad \blacksquare$$

Qué nos dice el Teorema de Eckart-Young?

- Reducir la dimensionalidad de A al "recortar" las componentes menos significativas (valores singulares pequeños) es la mejor manera de aproximar la matriz original.
- Si aplicamos ese procedimiento, el error introducido es el menor posible para el rango de matrices del mismo tamaño.
- Este hecho es muy importante para la disciplina del **Machine Learning** y da lugar al llamado "**Análisis de Componentes Principales**" (PCA).
- También es una forma de **compresión de datos**... DEMO