

Análisis Numérico II / Álgebra Lineal Numérica

Clase 10: Descomposición SVD: Aplicaciones




Facultad de Matemática,
Astronomía, Física y
Computación



Universidad
Nacional
de Córdoba

Los 4 Subespacios Fundamentales

Toda matriz $A \in \mathbb{R}^{m \times n}$ define una transformación lineal entre dos espacios vectoriales fundamentales: el **dominio de entrada** $\mathbb{R}^n$ y el **codominio de salida** $\mathbb{R}^m$.



Teorema (Descomposición en Valores Singulares)

Toda matriz real $A \in \mathbb{R}^{m \times n}$ de rango r puede descomponerse en un producto:

$$A = U\Sigma V^T$$

Donde:

- $U \in \mathbb{R}^{m \times m}$ y $V \in \mathbb{R}^{n \times n}$ son ortogonales.
- $\Sigma \in \mathbb{R}^{m \times n}$ es una matriz diagonal de estructura rectangular con valores singulares $\sigma_1 \geq \dots \geq \sigma_r > 0$ y $\sigma_{r+1} = \dots = \sigma_{\min(m,n)} = 0$.

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_r & & \\ & & & 0 & \end{bmatrix}$$

Teorema (Eckart-Young)

Sea $A \in \mathbb{R}^{m \times n}$ de rango r y $A = U\Sigma V^T$ su descomposición SVD. Para cualquier $k \in \{1, \dots, r\}$ podemos escribir:

$$A_k = \sum_{i=1}^k \sigma_i u^i (v^i)^T.$$

Entonces:

- A_k tiene rango k y
- $\min\{\|A - B\|_2 \mid B \in \mathbb{R}^{m \times n} \text{ de rango } k\} = \|A - A_k\|_2 = \sigma_{k+1}.$

Esto quiere decir que A_k es la mejor aproximación de rango k de la matriz A en términos de la norma 2.

Qué nos dice el Teorema de Eckart-Young?

- Reducir la dimensionalidad de A al "recortar" las componentes menos significativas (valores singulares pequeños) es la mejor manera de aproximar la matriz original.
- Si aplicamos ese procedimiento, el error introducido es el menor posible para el rango de matrices del mismo tamaño.
- Este hecho es muy importante para la disciplina del **Machine Learning** y da lugar al llamado "**Análisis de Componentes Principales**" (PCA).
- También es una forma de **compresión de datos** en imágenes.

Cuadrados Mínimos (again! :D)

$$\min_x \frac{1}{2} \|Ax - b\|_2^2$$

- Si nuestra matriz es $m \times n$, con $m > n$ y de rango completo, entonces podemos aplicar QR sin problemas.
- Cuando la matriz tiene rango deficiente ($r < n$), el problema se complica por tener $N(A)$ no trivial. ¿Cómo resolvemos en ese caso?
- Si x_p es una solución de $\arg \min_x \|Ax - b\|_2$, entonces $x_p + z$ **también es solución** para cualquier $z \in N(A)$:

$$A(x_p + z) - b = (Ax_p - b) + Az = Ax_p - b$$

Cuadrados Mínimos con Deficiencia de Rango

- La solución de cuadrados mínimos **no es única** (existe una familia infinita de soluciones).

Fallo de otros métodos:

- **Factorización QR** ($A = QR$): La matriz R tendrá ceros en la diagonal (singular, no invertible).
- **Ecuaciones Normales** ($A^T Ax = A^T b$): La matriz $A^T A$ es singular.

Solución de Norma Mínima

Cuando la solución no es única, se añade un segundo criterio para seleccionar una solución particular: la **solución de norma mínima** x^* .

Es el único vector x^* que satisface dos condiciones:

1. **Resuelve el problema de Cuadrados Mínimos:** $x^* = \arg \min_x \|Ax - b\|_2$.
2. **Tiene la menor norma 2:** $\|x^*\|_2 \leq \|x\|_2$ para cualquier otra solución x de CM.

Caracterización geométrica:

Esta condición es equivalente a exigir que la solución sea ortogonal al espacio nulo:

$$x^* \perp N(A) \quad \Longleftrightarrow \quad x^* \in \text{rango}(A^T)$$

Esta solución única se calcula de forma estable mediante la **SVD**.

Teorema

La solución de cuadrados mínimos de norma mínima x^* es ortogonal al espacio nulo, $x^* \perp N(A)$.

Demostración:

- Sea S el conjunto de todas las soluciones del problema de Cuadrados Mínimos:

$$S = \{x_p + z \mid z \in N(A)\}$$

donde x_p es una solución particular cualquiera.

- Descomponemos x_p en el espacio fila $\text{rango}(A^T)$ y en el espacio nulo $N(A)$:

$$x_p = x_r + x_n, \quad \text{con } x_r \in \text{rango}(A^T), \quad x_n \in N(A)$$

- Reescribimos S absorbiendo x_n en la variable general $z \in N(A)$:

Demostración

- **Minimización de la norma:** Queremos hallar $\arg \min_{x \in S} \|x\|_2^2$, lo cual equivale a:

$$\min_{z \in N(A)} \|x_r + z\|_2^2$$

- Como el espacio fila $\text{rango}(A^T)$ y el espacio nulo $N(A)$ son **complementos ortogonales**, $x_r \perp z$ para todo $z \in N(A)$. Por el **Teorema de Pitágoras**:

$$\|x_r + z\|_2^2 = \|x_r\|_2^2 + \|z\|_2^2$$

- El valor mínimo de $\|z\|_2^2$ es 0, el cual se alcanza únicamente cuando $z = 0$.

$$\therefore x^* = x_r + 0 = x_r \in \text{rango}(A^T) \implies x^* \perp N(A) \quad \blacksquare$$

Cálculo de x^* mediante SVD

Sea la descomposición $A = U\Sigma V^T$ con $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ ortogonales y $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0)$.

Aprovechando que la norma 2 se preserva por transformaciones ortogonales ($\|Uy\|_2 = \|y\|_2$):

$$\|Ax - b\|_2^2 = \|U\Sigma V^T x - b\|_2^2 = \|\Sigma(V^T x) - U^T b\|_2^2$$

Definimos $\tilde{x} = V^T x$ y $c = U^T b$. El problema equivale a minimizar:

$$\|\Sigma \tilde{x} - c\|_2^2 = \sum_{i=1}^r (\sigma_i \tilde{x}_i - c_i)^2 + \sum_{i=r+1}^m c_i^2$$

- Para minimizar el residuo, elegimos $\tilde{x}_i = \frac{c_i}{\sigma_i} = \frac{u_i^T b}{\sigma_i}$ para $1 \leq i \leq r$.
- El término $\sum_{i=r+1}^m c_i^2$ es el **residuo mínimo ineliminable**.

Solución Final y Pseudoinversa de Moore-Penrose

- Las componentes $\tilde{x}_{r+1}, \dots, \tilde{x}_n$ no afectan el residuo $\|Ax - b\|_2$.
- Para minimizar la norma $\|x\|_2 = \|\tilde{x}\|_2$, elegimos $\tilde{x}_i = 0$ para $i = r + 1, \dots, n$.

Recuperando $x^* = V\tilde{x}$:

$$x^* = \sum_{i=1}^r \frac{u_i^T b}{\sigma_i} v_i$$

Pseudoinversa de Moore-Penrose (A^+)

Definimos $A^+ = V\Sigma^+U^T$, donde $\Sigma^+ = \text{diag}\left(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}, 0, \dots, 0\right) \in \mathbb{R}^{n \times m}$.

La **solución única de norma mínima** para cuadrados mínimos viene dada por:

$$x^* = A^+ b$$

Algoritmo (Cuadrados Mínimos por SVD)

Entrada: $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y tolerancia $\text{tol} \geq 0$. **Salidas:** Solución de norma mínima $x^* \in \mathbb{R}^n$ y residuo mínimo $r_2 = \|Ax^* - b\|_2$.

- $U, \Sigma, V = \text{descomposicion_SVD}(A)$
- $c = U^T b$
- Definir $r = \max\{i : \sigma_i > \text{tol}\}$ (rango numérico de A)
- Definir $\mathcal{I} = \{1, \dots, r\}$, $\mathcal{J} = \{r + 1, \dots, m\}$
- Calcular $y_i = \frac{c_i}{\sigma_i}$ para $i \in \mathcal{I}$, y definir $y = \begin{bmatrix} y_{\mathcal{I}} \\ 0 \end{bmatrix} \in \mathbb{R}^n$
- $x^* = Vy$

Retornar: x^* y $r_2 = \|c_{\mathcal{J}}\|_2$

Resolución de Cuadrados Mínimos: Comparativa de Métodos Numéricos

Comparativa de los tres métodos principales para resolver problemas de cuadrados mínimos ($\min \|Ax - b\|_2$) bajo criterios de eficiencia, estabilidad y rango. La elección depende de las propiedades de la matriz A .

ECUACIONES NORMALES

$$A^T A x = A^T b$$

Factorización de Cholesky de la matriz simétrica $A^T A$

PROS

- Método directo y relativamente rápido

CONTRAS

- Sensible al cuadrado del número de condición $\kappa(A)^2$
- Estabilidad Numérica:** Baja (Menos estable)
- Comportamiento ante Rango Deficiente:** Pobre (No confiable)

FACTORIZACIÓN QR

$$A = QR$$

Transforma el problema en $Rx = Q^T b$ (sistema triangular superior)

PROS

- Más estable que Ecuaciones Normales
- Buen equilibrio entre costo y estabilidad

CONTRAS

- Duplica el costo de las Ecuaciones Normales
- Sensible a $\kappa(A)$

DESCOMPOSICIÓN SVD

$$A = U \Sigma V^T$$

Utiliza la pseudoinversa $x = V \Sigma^\dagger U^T b$ para máxima robustez

PROS

- Excelente estabilidad numérica (Máxima)
- Sensible a $\kappa(A)$
- Garantiza soluciones confiables en matrices de rango deficiente

CONTRAS

- Significativamente más costoso

Método	Costo (Flops aprox.)	Estabilidad Numérica	Condición Crítica	Manejo de Rango Deficiente
Ecuaciones Normales	 $mn^2 + \frac{1}{3}n^3$ (Bajo)	 Baja (Menos estable)	 $\kappa(A)^2$ (Sensible)	 Pobre
Factorización QR	 $2mn^2 - \frac{2}{3}n^3$ (Medio)	 Alta (Estable)	 $\kappa(A)$	 Bueno (Si Rango Completo)
Descomposición SVD	 $2mn^2 + 11n^3$ (Alto)	 Excelente (Máxima)	 $\kappa(A)$	 Excelente (Confiable)