

Análisis Numérico II / Álgebra Lineal Numérica

Clase 14: Métodos Iterativos de Separación



Facultad de Matemática,
Astronomía, Física y
Computación



Universidad
Nacional
de Córdoba

Por qué Métodos Iterativos?

Para resolver sistemas lineales $Ax = b$ de gran dimensión, los **métodos directos** (descomposiciones matriciales) presentan limitaciones computacionales:

- **Pérdida de Dispersión:** Aunque A sea una matriz rala o dispersa (con la gran mayoría de sus entradas nulas), los factores L y U suelen ser densos.
- **Costo de Almacenamiento:** Guardar factores densos exige $O(n^2)$ lugares de memoria, complicado para sistemas de gran porte en computación científica.
- **Costo Operacional:** Una factorización directa escala como $O(n^3)$ flops, sin importar los ceros que haya.
- **Alternativa:** Generar una sucesión de aproximaciones $\{x^{(k)}\}$ que converja a la solución exacta x^* conservando la matriz A intacta.

Métodos de Separación

La estrategia para construir un algoritmo iterativo estacionario consiste en realizar una **separación o descomposición de la matriz** $A \in \mathbb{R}^{n \times n}$ de la forma:

$$A = M - N$$

Reescribiendo el sistema original $Ax = b$ mediante esta separación:

$$(M - N)x = b \implies Mx = Nx + b$$

- **Matriz Precondicionadora (M):** Fácil de invertir (ej. diagonal o triangular).
- **Ecuación de Recurrencia:** Se define el esquema iterativo:

$$\begin{aligned} Mx^{(k+1)} &= Nx^{(k)} + b \\ x^{(k+1)} &= M^{-1}Nx^{(k)} + M^{-1}b = G(x^{(k)}) \end{aligned}$$

Punto Fijo!

Teorema: Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$, $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ y suponga que existe $\tau \in [0, 1)$ tal que $\|F(y) - F(x)\| \leq \tau\|y - x\|$ para todo $x, y \in \mathbb{R}^n$. Entonces existe x^* tal que $x^* = F(x^*)$ y dicho punto es único. Más aún, para cualquier $x^0 \in \mathbb{R}^n$ la sucesión $\{x^k\}$ generada por $x^{k+1} = F(x^k)$ converge a x^* .

Corolario: Sea $\{x^k\}$ generada por (7.1). Si M es no singular y para alguna norma matricial inducida vale que $\|M^{-1}N\| < 1$, entonces para cualquier $x^0 \in \mathbb{R}^n$ la sucesión $\{x^k\}$ converge a x^* con $Ax^* = b$. Además, vale que

$$\|x^{k+1} - x^*\| \leq \frac{\|M^{-1}N\|}{1 - \|M^{-1}N\|} \|x^{k+1} - x^k\|.$$

Demostración:

- Como la sucesión cumple que $x^{k+1} = G(x^k)$ con $G(x) = M^{-1}Nx + M^{-1}b$, si $\tau = \|M^{-1}N\| < 1$ entonces

$$\|G(y) - G(x)\| = \|M^{-1}N(y - x)\| \leq \tau\|y - x\|.$$

- El Teorema anterior garantiza que $\lim_{k \rightarrow \infty} x^k = x^*$ con $Ax^* = b$.
- Como x^* es un punto fijo de G ,

$$\begin{aligned}\|x^{k+1} - x^*\| &= \|G(x^k) - G(x^*)\| \leq \tau\|x^k - x^*\| \\ &\leq \tau\|x^{k+1} - x^k\| + \tau\|x^{k+1} - x^*\|.\end{aligned}$$

- Usando que $\tau < 1$, despejamos $\|x^{k+1} - x^*\|$ y obtenemos lo deseado. ■

Esto es una condición SUFICIENTE!!!

Descomposición Canónica de A

Para derivar los métodos clásicos de separación, particionamos la matriz A en sus tres componentes estructurales:

$$A = D + L + U$$

donde:

- D : Matriz diagonal con las entradas diagonales de A (a_{ii}).
- L : Matriz triangular inferior estricta con las entradas por debajo de la diagonal (a_{ij} con $i > j$).
- U : Matriz triangular superior estricta con las entradas por encima de la diagonal (a_{ij} con $i < j$).

Revisemos el Método de Jacobi

La elección de las matrices M y N da origen a distintos algoritmos, por ejemplo:

Método de Jacobi: Tomemos $M_J = D$ y $N_J = -(L + U)$.

$$Dx^{(k+1)} = -(L + U)x^{(k)} + b$$

Definición: Decimos que una matriz A es diagonalmente dominante por filas (columnas) si:

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{i,j}| \quad \left(|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^m |a_{i,j}| \right)$$

Iteración de Jacobi

$$x_i^{k+1} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^k \right), \quad i = 1, \dots, n.$$

Cuándo converge?

Proposición: Si $A \in \mathbb{R}^{n \times n}$ es diagonalmente dominante entonces

$$\|M_J^{-1}N_J\|_\infty < 1.$$

Demostración: Por definición de $M_J, N_J, \|\cdot\|_\infty$ y la hipótesis sobre A , tenemos

$$\|M_J^{-1}N_J\|_\infty = \max_{1 \leq i \leq n} \sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1. \blacksquare$$

Algoritmo: Iteración de Jacobi

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$. **Salida:** x^+ aproximación de x^* .

1. Si $A_{ii} = 0$ para algún i , parar y retornar un error.

Sino, para $A = L + D + U$, hacer

$$b \leftarrow D^{-1}b,$$

$$A \leftarrow D^{-1}(L + U).$$

2. Para $k = 1, \dots, m$, definir

$$x^+ = b - Ax.$$

Si $\|x^+ - x\|_\infty \leq \epsilon$ ir al paso 3. Sino, hacer $x = x^+$.

3. Retornar x^+ .

Iteración de Gauss-Seidel

La iteración de Gauss-Seidel se define tomando $M_{GS} = D + L$ y $N_{GS} = -U$:

$$M_{GS}x^{k+1} = N_{GS}x^k + b$$

Escribiendo las componentes de esta ecuación, se tiene que:

$$x_i^{k+1} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{k+1} - \sum_{j=i+1}^n a_{ij}x_j^k \right), \quad i = 1, \dots, n.$$

- Cada componente actualizada x_i^{k+1} se utiliza inmediatamente en el cálculo de las componentes siguientes dentro de la misma iteración.

Convergencia de Gauss-Seidel

Veamos que se cumple un resultado análogo al de la iteración de Jacobi:

Proposición: Si $A \in \mathbb{R}^{n \times n}$ es diagonalmente dominante en sentido estricto entonces:

$$\|M_{GS}^{-1}N_{GS}\|_{\infty} < 1.$$

Corolario: Si $A \in \mathbb{R}^{n \times n}$ es diagonalmente dominante en sentido estricto, entonces para cualquier $x^0 \in \mathbb{R}^n$ la sucesión $\{x^k\}$ generada por la iteración de Gauss-Seidel converge a x^* con $Ax^* = b$.

Algoritmo: Iteración de Gauss-Seidel

Entradas: $A \in \mathbb{R}^{n \times n}$, $b, x \in \mathbb{R}^n$, $\epsilon > 0$ y $k_{\text{máx}} \in \mathbb{N}$. **Salida:** x^+ aprox. de x^* .

1. Si $A_{ii} = 0$ para algún i , parar y retornar un error.

Sino, para $A = L + D + U$, hacer

$$\begin{aligned} b &\leftarrow (L + D)^{-1}b, \\ A &\leftarrow D^{-1}(L + U), \\ x^+ &\leftarrow x. \end{aligned}$$

2. Para $k = 1, \dots, k_{\text{máx}}$:

- Para $i = 1, \dots, n$, definir $x_i^+ \leftarrow b_i - A_{i*}x^+$.
- Si $\|x^+ - x\|_\infty \leq \epsilon$ ir al paso 3. Sino, hacer $x = x^+$.

3. Retornar x^+ .

Iteración SOR (Sobrerelajación Sucesiva)

La iteración SOR (*Successive Over Relaxation*) requiere un parámetro de relajación $\omega > 0$ y considera $M_{SOR} = \frac{1}{\omega}D + L$ y $N_{SOR} = \left(\frac{1}{\omega} - 1\right)D - U$, o sea:

- Gauss-Seidel es el caso particular con $\omega = 1$.
- **Convergencia:** Si A es simétrica definida positiva y $0 < \omega < 2$, entonces:

$$\|M_{SOR}^{-1}N_{SOR}\| < 1$$

para cierta norma matricial inducida $\|\cdot\|$.

Ventajas de los Métodos de Separación

- **Aprovechamiento de la Dispersión:**
 - Explotan naturalmente matrices ralas, evitan *fill-in* (llenado de matrices).
 - Costo por iteración mínimo: un producto matriz-vector y resolver con M .
- **Simplicidad Computacional y Paralelismo:**
 - "Fácil" implementación y requisitos mínimos de memoria.
 - Algunos de ellos son paralelizables (por ejemplo, Jacobi).
- **Flexibilidad y Precondicionamiento:**
 - La matriz M actúa como matriz preconditionadora.
 - Son piezas fundamentales para métodos modernos más robustos (soon).

Limitaciones de los Métodos de Separación

- **Garantías y Velocidad de Convergencia:**
 - Si $\rho(M^{-1}N) \geq 1$, el método diverge.
 - Convergencia puede ser excesivamente lenta y exigir condiciones fuertes.
- **Rendimiento Subóptimo a Gran Escala:**
 - Para sistemas lineales de gran dimensión (n grande), los esquemas básicos como Jacobi o SOR son inferiores a técnicas avanzadas.
- **Dificultades en Aceleración Polinomial:**
 - Con ciertas separaciones (como en SOR), la matriz de iteración puede tener autovalores sobre círculos o distribuciones complejas, limitando la efectividad.

Casos de Uso y Aplicaciones

- **Discretización de Ecuaciones Diferenciales Parciales (EDPs):**
 - Muy comunes al aplicar diferencias finitas o elementos finitos.
 - Las matrices resultantes son enormes, altamente dispersas y con estructuras bien definidas (p. ej., matrices banda o diagonales dispersas).
- **Precondicionadores en Métodos de Krylov:**
 - Su uso moderno más importante: elegir $M \approx A$ fácil de invertir tal que el sistema preconditionado $M^{-1}Ax = M^{-1}b$ tenga $\kappa(M^{-1}A) \ll \kappa(A)$.
 - Un menor número de condición acelera enormemente la convergencia de métodos como **Gradiente Conjugado** (soon) o **GMRES**.