

Análisis Numérico II / Álgebra Lineal Numérica

Clase 15: Métodos de Proyección



Facultad de Matemática,
Astronomía, Física y
Computación



Universidad
Nacional
de Córdoba

Falta de Acceso al Error

Dada la ecuación lineal $Ax = b$ con $A \in \mathbb{R}^{n \times n}$ no singular, busquemos aproximar la solución exacta x^* .

- Nos gustaría tener un algoritmo que minimice el **error exacto** en la iteración k :

$$e^k = x^* - x^k$$

- Para medir o evaluar e^k , necesitaríamos conocer previamente x^* . ¡Pero x^* es justamente la incógnita que deseamos calcular!
- Ningún algoritmo computable puede basar la elección de la dirección de avance en corregir directamente e^k .

Una Alternativa Calculable

Al no tener acceso a x^* , recurrimos a la única magnitud medible que evalúa la discrepancia del sistema: el **vector residuo** r^k .

$$r^k = b - Ax^k = A(x^* - x^k) = Ae^k \implies e^k = A^{-1}r^k$$

- A diferencia del error, r^k es calculable. Pero la norma del residuo no siempre refleja la magnitud del error:

$$\frac{\|e^k\|}{\|x^*\|} \leq \kappa(A) \frac{\|r^k\|}{\|b\|}$$

- Si $\kappa(A) \gg 1$, un residuo pequeño $\|r^k\| \approx 0$ no garantiza que el error $\|e^k\|$ sea pequeño.

Espacios de Krylov

¿Dónde buscamos la corrección para x^0 si sólo podemos multiplicar la matriz A por vectores?

- Partimos del único vector con información del error: el residuo inicial $r^0 = b - Ax^0$.
- Aplicando el operador A de forma recurrente, extraemos las direcciones principales de variación:

$$\{r^0, Ar^0, A^2r^0, \dots, A^{k-1}r^0\}$$

- **Definición (Subespacio de Krylov $\mathcal{K}_k(A, r^0)$):**

$$\mathcal{K}_k(A, r^0) = \text{span}\{r^0, Ar^0, A^2r^0, \dots, A^{k-1}r^0\} \subset \mathbb{R}^n$$

Cómo Resolveríamos el Error?

- **Propuesta de Búsqueda:** Buscamos la nueva aproximación en el espacio afín:

$$x^k \in x^0 + \mathcal{K}_k(A, r^0) \implies x^k = x^0 + p_{k-1}(A)r^0$$

donde p_{k-1} es un polinomio de grado a lo sumo $k - 1$.

Al restringir la solución al subespacio $\mathcal{K}_k(A, r^0)$, los algoritmos seleccionan el "mejor" x^k imponiendo condiciones de optimización realizables:

Dos Métodos Insignia

1. Método de Gradiente Conjugado (CG) [para A SDP]:

Impone la condición de ortogonalidad de Galerkin: $r^k \perp \mathcal{K}_k(A, r^0)$.

Esto equivale geométricamente a minimizar el error inaccesible en la norma- A :

$$\min_{x^k \in x^0 + \mathcal{K}_k} \|x^* - x^k\|_A$$

2. Método GMRES [para A general]:

Minimiza la norma Euclídea del residuo computable sobre el subespacio:

$$\min_{x^k \in x^0 + \mathcal{K}_k} \|b - Ax^k\|_2$$

Método de Gradiente Conjugado (CG)

Para resolver $Ax = b$ con $A \in \mathbb{R}^{n \times n}$ **Simétrica Definida Positiva (SDP)**, construiremos la sucesión $\{x^k\}$ en un subespacio de Krylov en expansión:

- Buscamos una base $\{p^1, \dots, p^k\}$ tal que $\text{span}(p^1, \dots, p^k) = \mathcal{K}_k(A, b)$
- Si conocemos la base y los coeficientes escalares μ_k , la solución se escribe como:

$$x^* = \sum_{k=1}^n \mu_k p^k \quad \Longrightarrow \quad x^k = \sum_{l=1}^k \mu_l p^l$$

- Esto permite una **regla de actualización aditiva simple**:

$$x^{k+1} = x^k + \mu_{k+1} p^{k+1}$$

Nuestro objetivo es determinar las **direcciones de búsqueda** p^k y las **longitudes de paso** μ_k de forma eficiente.

Intento 1: Base Ortogonal Estándar

¿Por qué no elegir una base ortogonal ordinaria $\{q^1, \dots, q^n\}$?

- Tomemos $p^k = q^k$ y agrupemos $P = [p^1, \dots, p^n] \in \mathbb{R}^{n \times n}$ con $P^T P = I$.
- Escribiendo $x^* = P\mu$, con $\mu = [\mu_1, \dots, \mu_n]^T$:

$$P^T x^* = P^T P \mu = I \mu = \mu \quad \implies \quad \mu_k = (p^k)^T x^*$$

$$\mu_k = (p^k)^T x^* \quad ; \text{ requiere conocer } x^* \text{ de antemano!}$$

- Llegamos a la misma paradoja: para calcular los coeficientes necesitaríamos la propia incógnita que deseamos hallar.
- La ortogonalidad usual no es suficiente. Requerimos una base diferente y más astuta.

Intento 2: Una Nueva Condición de Optimalidad

En lugar de proyectar x^* , utilicemos la relación del sistema que sí conocemos: $Ax^* = b$

.

- Multipliquemos por la izquierda por la matriz P^T : $P^T Ax^* = P^T b$
- Como b es un dato del problema, $P^T b$ es calculable.
- Insertando la descomposición $x^* = P\mu$ en esta ecuación:

$$P^T A(P\mu) = P^T b \quad \implies \quad (P^T AP)\mu = P^T b$$

- Eliminamos x^* de la ecuación! Resolvemos este sistema lineal para encontrar μ .

A-Ortogonalidad (Conjugación)

¿Cómo podemos lograr que el sistema $(P^T A P)\mu = P^T b$ sea trivial de resolver?

- Elegimos la base $\{p^k\}$ de modo que la matriz proyectada sea **diagonal**:

$$P^T A P = D = \text{diag}(d_1, \dots, d_n)$$

- Esto equivale a exigir que $(p^i)^T A p^j = 0$ para todo $i \neq j$
- Esta propiedad se denomina **A-ortogonalidad** o **conjugación** respecto de A .
- El sistema lineal queda completamente desacoplado y cada coeficiente se calcula directamente 😊

$$\mu_k = \frac{(p^k)^T b}{d_k} = \frac{(p^k)^T b}{(p^k)^T A p^k}$$

El A -Producto Interno

Definición: Dada $A \in \mathbb{R}^{n \times n}$ (SDP), el A -producto interno entre dos vectores $y, z \in \mathbb{R}^n$ se define como:

$$\langle y, z \rangle_A = y^T A z$$

- Es un producto interno bien definido precisamente porque A es SDP:
 - **Simetría:** $\langle y, z \rangle_A = y^T A z = (y^T A z)^T = z^T A^T y = z^T A y = \langle z, y \rangle_A$.
 - **Bilinealidad:** Directa por la linealidad del producto matricial.
 - **Positividad:** $\langle y, y \rangle_A = y^T A y > 0$ para todo $y \neq 0$.

Exigir $P^T A P = D$ significa que los $\{p^k\}$ son ortogonales respecto a la métrica inducida por A .

Interpretación Geométrica (con Cholesky)

Sabemos que $A = G^T G$, luego

$$\langle y, z \rangle_A = y^T A z = y^T (G^T G) z = (Gy)^T (Gz) = \langle Gy, Gz \rangle_2$$

- El A -producto interno es el **producto escalar euclídeo** de los vectores transformados por el factor de Cholesky.
- **Geometría de la transformación:**
 - G actúa como un cambio de coordenadas que transforma los elipsoides de nivel $y^T A y = \text{cte}$ en esferas estándar $\|Gy\|_2^2 = \text{cte}$.
 - Dos vectores son **A -ortogonales** si y sólo si sus imágenes por G son **ortogonales euclídeas**:

$$(p^i)^T A p^j = 0 \iff (Gp^i) \perp (Gp^j)$$

Norma- A y Garantía de Optimalidad

El A -producto interno define la **norma- A** : $\|z\|_A = \sqrt{\langle z, z \rangle_A} = \sqrt{z^T A z}$

Teorema: En el paso k , el error exacto $e^k = x^* - x^k$ es **A -ortogonal** a todo $\mathcal{K}_k$. Para cada $l \leq k$, tenemos:

$$(p^l)^T A(x^* - x^k) = (p^l)^T b - \sum_{i=1}^k \mu_i ((p^l)^T A p^i) = (p^l)^T b - \mu_l d_l = (p^l)^T b - d_l \left(\frac{(p^l)^T b}{d_l} \right) = 0$$

Al ser el error A -ortogonal a $\mathcal{K}_k$, x^k es la **proyección ortogonal** de x^* sobre $\mathcal{K}_k$ bajo la norma- A :

$$x^k = \operatorname{argmin}_{y \in \mathcal{K}_k} \|x^* - y\|_A$$

En cada iteración, CG produce la **mejor aproximación posible** a la solución exacta dentro de $\mathcal{K}_k$ en la métrica inducida por A .

Generación Eficiente de Direcciones

Para generar las direcciones $\{p^k\}$, un proceso tipo Gram-Schmidt requeriría guardar todos los vectores anteriores.

La clave es usar el **vector residuo**: $r^k = b - Ax^k$ (con $r^0 = b$ si $x^0 = 0$)

- Recordemos que $\mathcal{K}_k = \text{span}(b, Ab, \dots, A^{k-1}b)$.
- Si $x^{k-1} \in \mathcal{K}_{k-1}$, entonces por definición de Krylov, $Ax^{k-1} \in \mathcal{K}_k$.
- Como $b \in \mathcal{K}_k$ y $Ax^{k-1} \in \mathcal{K}_k$, se deduce que $r^{k-1} = b - Ax^{k-1} \in \mathcal{K}_k$
- Por lo tanto, todos los residuos previos pertenecen al subespacio:

$$\text{span}(r^0, \dots, r^{k-1}) \subset \text{span}(p^1, \dots, p^k) = \mathcal{K}_k$$

Ortogonalidad de los Residuos

Teorema: El residuo en el paso k , $r^k = b - Ax^k$, es ortogonal a todo el subespacio $\mathcal{K}_k$.

Demostración: Basta verificar que $(p^l)^T r^k = 0$ para todo $1 \leq l \leq k$:

$$(p^l)^T r^k = (p^l)^T (b - Ax^k) = (p^l)^T b - (p^l)^T A \left(\sum_{i=1}^k \mu_i p^i \right) = (p^l)^T b - \sum_{i=1}^k \mu_i ((p^l)^T A p^i)$$

Por la condición de A -ortogonalidad, $(p^l)^T A p^i = 0$ si $i \neq l$, y además $(p^l)^T b = \mu_l d_l$:

$$(p^l)^T r^k = (p^l)^T b - \mu_l ((p^l)^T A p^l) = d_l \mu_l - \mu_l d_l = 0$$

Como se anula para todo $l \leq k$, el residuo r^k es perpendicular a todo vector de $\mathcal{K}_k$. ■

Equivalencia de Subespacios

Teorema: $\text{span}(r^0, \dots, r^{k-1}) = \mathcal{K}_k = \text{span}(p^1, \dots, p^k)$

Demostración:

- Como $\text{span}(r^0, \dots, r^{k-1}) \subset \mathcal{K}_k$, para cualquier $l < k$, tenemos $r^l \in \mathcal{K}_{l+1} \subset \mathcal{K}_k$.
- Como $r^k \perp \mathcal{K}_k$, r^k es ortogonal a todo vector dentro de él, en particular a los residuos previos:

$$(r^k)^T r^l = 0 \quad \text{para todo } l < k$$

- Si el algoritmo no convergió antes ($r^k = 0 \iff x^k = x^*$), todos los residuos son no nulos $\implies$ son linealmente independientes y su dimensión es k . ■

La Recurrencia Corta de Tres Términos

Como $r^k \in \mathcal{K}_{k+1} = \text{span}(p^1, \dots, p^{k+1})$, podemos escribir $r^k = \sum_{l=1}^{k+1} u_{l,k+1} p^l$

Tomando producto interno- A con p^i para $i \leq k+1$:

$$(p^i)^T A r^k = \sum_{l=1}^{k+1} u_{l,k+1} ((p^i)^T A p^l) = u_{i,k+1} d_i \quad \implies \quad u_{i,k+1} = \frac{(A p^i)^T r^k}{d_i}$$

- $p^i \in \mathcal{K}_i \implies A p^i \in \mathcal{K}_{i+1}$.
- Si $i < k$, entonces $\mathcal{K}_{i+1} \subset \mathcal{K}_k$.
- Como $r^k \perp \mathcal{K}_k$, necesariamente $(A p^i)^T r^k = 0$ para todo $i < k$.
- Por lo tanto: $u_{i,k+1} = 0$ para todo $i < k$

Colapso a Dos Términos

¡Todos los coeficientes anteriores a k se anulan idénticamente! La expansión colapsa a:

$$r^k = u_{k,k+1}p^k + u_{k+1,k+1}p^{k+1}$$

Despejando la nueva dirección p^{k+1} y fijando la normalización estándar $u_{k+1,k+1} = 1$:

$$p^{k+1} = r^k - u_{k,k+1}p^k \quad \text{con } u_{k,k+1} = \frac{(p^k)^T A r^k}{d_k}$$

Para construir p^{k+1} , sólo usamos el residuo actual r^k y la dirección anterior p^k .

No necesitamos almacenar ni ortogonalizar contra toda la historia previa!

Esta recurrencia corta es lo que vuelve a CG rápido y económico en memoria.

Fórmulas Eficientes: El Paso μ_k

Podemos simplificar el cálculo de $\mu_k = \frac{(p^k)^T b}{d_k}$ eliminando productos innecesarios:

- Como $r^{k-1} = b - Ax^{k-1}$, tenemos $b = r^{k-1} + Ax^{k-1}$. Sustituyendo en el numerador: $(p^k)^T b = (p^k)^T r^{k-1} + (p^k)^T Ax^{k-1}$
- Pero $x^{k-1} \in \mathcal{K}_{k-1}$ y por construcción p^k es A -ortogonal a $\mathcal{K}_{k-1}$, por lo que $(p^k)^T Ax^{k-1} = 0$, de donde $(p^k)^T b = (p^k)^T r^{k-1}$
- Por la recurrencia, $p^k = r^{k-1} - u_{k-1,k}p^{k-1}$. Como $p^{k-1} \perp r^{k-1}$,
 $(p^k)^T r^{k-1} = (r^{k-1} - u_{k-1,k}p^{k-1})^T r^{k-1} = \|r^{k-1}\|_2^2$
- Obtenemos la fórmula computacional óptima: $\mu_k = \frac{\|r^{k-1}\|_2^2}{(p^k)^T Ap^k}$

Fórmulas Eficientes: El Factor de Dirección τ_k

Calculemos ahora el coeficiente de actualización de dirección $u_{k,k+1} = \frac{(Ap^k)^T r^k}{d_k}$:

- De la actualización del residuo: $r^k = r^{k-1} - \mu_k Ap^k \implies Ap^k = \frac{1}{\mu_k} (r^{k-1} - r^k)$

- Sustituyendo este valor en el producto interno:

$$(Ap^k)^T r^k = \frac{1}{\mu_k} (r^{k-1} - r^k)^T r^k = \frac{1}{\mu_k} \underbrace{((r^{k-1})^T r^k)}_{=0} - \frac{\|r^k\|_2^2}{\mu_k}$$

- Usando la relación $\mu_k d_k = \|r^{k-1}\|_2^2$: $u_{k,k+1} = \frac{-(1/\mu_k)\|r^k\|_2^2}{d_k} = -\frac{\|r^k\|_2^2}{\mu_k d_k} = -\frac{\|r^k\|_2^2}{\|r^{k-1}\|_2^2}$

- Definiendo el parámetro $\tau_k = -u_{k,k+1}$: $\tau_k = \frac{\|r^k\|_2^2}{\|r^{k-1}\|_2^2}$ y por lo tanto

$$p^{k+1} = r^k + \tau_k p^k$$

Algoritmo: *Gradiente Conjugado (CG)*

Entradas: $A \in \mathbb{R}^{n \times n}$ SDP, $b \in \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$, $m \in \mathbb{N}$.

1. Inicialización:

$$r^0 = b - Ax^0, \quad p^1 = r^0, \quad \rho_0 = \|r^0\|_2^2$$

2. Para $k = 1, 2, \dots, m$: Si $\sqrt{\rho_{k-1}} < \epsilon$, parar y retornar x^{k-1} .

- $v^k = Ap^k, \mu_k = \frac{\rho_{k-1}}{(p^k)^T v^k}$
- $x^k = x^{k-1} + \mu_k p^k$
- $r^k = r^{k-1} - \mu_k v^k$
- $\rho_k = \|r^k\|_2^2, \tau_k = \frac{\rho_k}{\rho_{k-1}}$
- $p^{k+1} = r^k + \tau_k p^k$

3. Retornar: x^k .

Eficiencia Computacional y Memoria

Cada iteración de CG requiere un costo mínimo y estrictamente controlado:

- **Operaciones por iteración:**
 - **1 producto matriz-vector** (Ap^k): Escala como $O(\text{nnz}(A))$. En matrices ralas o estructuradas, esto es $O(n)$ flops.
 - **2 productos escalares:** $(p^k)^T(Ap^k)$ y $\rho_k = (r^k)^T r^k$ ($O(n)$ flops).
 - **3 actualizaciones de vectores tipo saxpy:** x^k, r^k, p^{k+1} ($O(n)$ flops).
- **Requisitos de Almacenamiento:**
 - Sólo requiere almacenar en memoria un puñado de vectores: x, r, p y $v = Ap$.
 - No se almacena la base de Krylov completa ni matrices densas intermedias.

Condición Crucial: El método exige que la matriz A sea **Simétrica y Definida**

¿Por qué "Gradiente Conjugado"?

El nombre refleja literalmente los dos pilares teóricos del método:

1. La parte "Gradiente":

- CG minimiza el error en norma- A :

$$L(y) = \frac{1}{2} \|x^* - y\|_A^2 = \frac{1}{2} (x^* - y)^T A (x^* - y)$$

- El gradiente de esta función de costo respecto de y es:

$$\nabla L(y) = Ay - Ax^* = Ay - b = -r(y)$$

- El residuo r^k es exactamente la dirección de máximo descenso (-gradiente).

2. La parte "Conjugado":

- El método de *Steepest Descent* avanza simplemente por r^k , pero zigzaguea
necesariamente cuando $\kappa(A) \gg 1$

Resumen de Relaciones Matriciales

Definiendo las matrices cuyas columnas agrupan los vectores generados:

- $Q = [q^1, \dots, q^n]$: Vectores ortonormales de Lanczos.
- $P = [p^1, \dots, p^n]$: Direcciones A -ortogonales de CG.
- $R = [r^0, \dots, r^{n-1}]$: Residuos de CG.

Estructura	Relación	Propiedad Fundamental
Identidad	$Q^T Q = I$	Lanczos ortonormales
Diagonal	$R^T R = D_R$	Residuos mutuamente ortogonales
Diagonal	$P^T A P = D$	Direcciones A -ortogonales (conjugadas)
Tridiagonal Simétrica	$Q^T A Q = T$	Reducción tridiagonal del proceso de Lanczos
Tridiagonal Simétrica	$R^T A R = T_R$	Los residuos forman una base tridiagonal

Conexión Profunda con el Proceso de Lanczos

CG y Lanczos son dos caras de la misma moneda.

- **Vectores Paralelos:** Como $r^{k-1} \perp \mathcal{K}_{k-1}$ y $q^k \perp \mathcal{K}_{k-1}$, y el complemento ortogonal $\mathcal{K}_k \ominus \mathcal{K}_{k-1}$ tiene dimensión 1:

$$\text{span}(r^{k-1}) = \text{span}(q^k)$$

Los residuos de CG son, salvo una constante de escala, los vectores ortogonales de Lanczos.

- **Resolución Implícita del Sistema Tridiagonal:**

Escribiendo la solución en la base de Lanczos $x^k = Q_k y^k$, la condición $r^k \perp \mathcal{K}_k$ es:

$$Q_k^T(b - Ax^k) = 0 \implies (Q_k^T A Q_k) y^k = Q_k^T b \implies T_k y^k = \|b\|_2 e^1$$

Conclusión Profunda: Gradiente Conjugado resuelve implícitamente el sistema tridiagonal $T_k y^k = \|b\|_2 e^1$ paso a paso mediante recurrencias cortas, sin

Convergencia de Gradiente Conjugado

¿Qué tan rápido converge la aproximación hacia x^* ?

- **Convergencia Finita (Teórica):**

- En aritmética exacta, como los residuos no nulos son mutuamente ortogonales en $\mathbb{R}^n$, CG encuentra la solución exacta en **a lo sumo n pasos**.
- En la práctica ($n \approx 10^5 - 10^7$), correr n pasos es impensable, y los errores de redondeo destruyen la ortogonalidad exacta.
- El verdadero objetivo de CG es aproximar excelentemente en $k \ll n$ iteraciones.

- **Cota de Error en Función del Número de Condición:**

Para A SDP con $\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$, se cumple la cota clásica:

$$\left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k$$

Interpretación de la Cota de Convergencia

Analicemos el factor de reducción del error $\rho = \frac{\sqrt{\kappa(A)}-1}{\sqrt{\kappa(A)}+1}$:

- **Matriz Bien Condicionada ($\kappa(A) \approx 1$):**
 - $\sqrt{\kappa(A)} \approx 1 \implies \rho \approx 0$.
 - El error decae exponencialmente y la convergencia se logra en un puñado de iteraciones.
- **Matriz Mal Condicionada ($\kappa(A) \gg 1$):**
 - $\sqrt{\kappa(A)}$ es grande $\implies \rho \approx 1 - \frac{2}{\sqrt{\kappa(A)}} \approx 1$.
 - La reducción de error por iteración es muy lenta.

Importante: A diferencia de los métodos estacionarios (donde la tasa suele depender de $1 - O(1/\kappa)$), CG depende de $\sqrt{\kappa(A)}$. ¡La raíz cuadrada representa

Agrupamiento de Autovalores (*Clustering*)

La cota con $\kappa(A)$ es un escenario pesimista de peor caso. La tasa real depende fuertemente de la **distribución espectral** de A :

- **Autovalores Idénticos o Discretos:**
 - Si A tiene sólo m autovalores distintos, CG converge en exactamente a lo sumo m pasos, sin importar cuán grande sea n .
 - Si los autovalores forman m agrupamientos densos (*clusters*), CG se comporta prácticamente como si resolviera un sistema de tamaño m .
- **La Clave del Precondicionamiento:**
 - Modificar el sistema $Ax = b$ multiplicando por $M^{-1} \approx A^{-1}$ de modo que $M^{-1}A$ tenga autovalores concentrados alrededor de 1 y $\kappa(M^{-1}A) \approx 1$.
 - Es la herramienta fundamental que permite resolver problemas gigantescos en

El Fenómeno de Convergencia Superlineal

En aplicaciones prácticas, suele observarse que la convergencia de CG se acelera a medida que avanzan las iteraciones:

- **Mecanismo Espectral:**
 - La iteración de Lanczos (y por ende CG) captura primero los autovalores y direcciones extremas del espectro (aproximaciones de Ritz).
 - A medida que se neutralizan estas componentes en el error, el algoritmo opera eficazmente sobre un subespacio complementario con un **número de condición efectivo menor**:

$$\kappa_{\text{eff}} < \kappa(A)$$

- **Efecto de Bola de Nieve:**
 - Al reducirse el κ_{eff} , la tasa de convergencia local mejora progresivamente en

Resumen: Lo Esencial de Gradiente Conjugado

Concepto	Expresión Matemática	Significado Práctico
Subespacio	$\mathcal{K}_k(A, r^0) = \text{span}(p^1, \dots, p^k) = \text{span}(r^0, \dots, r^{k-1})$	Los residuos y direcciones generan el mismo Krylov
A -Ortogonalidad	$(p^i)^T A p^j = 0 \quad (i \neq j)$	Direcciones conjugadas: desacoplan la