Análisis Numérico II / Álgebra Lineal Numérica

Clase 16: Método GMRES



La Iteración de Arnoldi

Construcción de Bases Ortonormales en Subespacios de Krylov

- **Origen:** Algoritmo desarrollado por Walter Edwin Arnoldi (1951).
- **Propósito:** Construir una base ortonormal para un subespacio de Krylov y proyectar matrices de gran dimensión.
- **Aplicación:** Cálculo de valores propios y resolución de sistemas lineales de gran escala (ej. GMRES).

Recordemos: Subespacios de Krylov

Para una matriz $A \in \mathbb{R}^{n \times n}$ y un vector inicial $b \in \mathbb{R}^n \setminus \{0\}$, el **subespacio de Krylov** de orden k se define como:

$$\mathcal{K}_k(A, b) = \text{span}\{b, Ab, A^2b, \ldots, A^{k-1}b\}$$

- Representa el espacio formado por polinomios aplicados a la matriz: $\mathcal{K}_k(A, b) = \{p(A)b : \text{grado}(p) \leq k - 1\}$.
- Para n muy grande, operar directamente sobre $\mathbb{R}^n$ es costoso; reducir el problema a $\mathcal{K}_k(A, b)$ permite aproximar soluciones con $k \ll n$.

El Problema de la Base Monomial

La secuencia de vectores $\{b, Ab, A^2b, \ldots, A^{k-1}b\}$ presenta graves problemas numéricos:

- **Inestabilidad por mal condicionamiento:** A medida que k crece, los vectores A^jb se alinean paulatinamente con el autovector dominante de A (comportamiento del método de las potencias).
- **Pérdida de independencia lineal:** La base natural se vuelve casi linealmente dependiente.
- **Solución:** Ortogonalizar la secuencia a medida que se genera utilizando el método de **Gram-Schmidt Modificado**.

Algoritmo de la Iteración de Arnoldi

Dado $A \in \mathbb{R}^{n \times n}$ y vector de inicio b:

1. Normalizar el vector inicial: $q_1 = \frac{b}{\|b\|_2}$
2. Para $k = 1, 2, \ldots, m$:
   - Calcular nuevo candidato: $v = Aq^k$
   - Ortogonalizar frente a la base previa $q^1, \ldots, q^k$:

$$h_{j,k} = (q^j)^T v, \quad v \leftarrow v - h_{j,k} q^j \quad (j = 1, \ldots, k)$$

   - Normalizar el nuevo vector ortogonal:

$$h_{k+1,k} = \|v\|_2, \quad q^{k+1} = \frac{v}{h_{k+1,k}}$$

Relación Matricial

De la ortogonalización se deriva la relación paso a paso:

$$Aq^k = \sum_{j=1}^{k+1} h_{j,k} q^j$$

Agrupando en forma matricial para las primeras k iteraciones:

$$AQ_k = Q_k H_k + h_{k+1,k} q^{k+1} (e^k)^T$$

- $Q_k = [q^1, q^2, \ldots, q^k] \in \mathbb{R}^{n \times k}$ tiene columnas ortonormales ($Q_k^* Q_k = I_k$).
- $H_k \in \mathbb{R}^{k \times k}$ es una matriz **Hessenberg superior**.
- $e^k = [0, \ldots, 0, 1]^T \in \mathbb{R}^k$.

Estructura de la Matriz Hessenberg H_k

Dado que $Q_k^* Q_k = I_k$, la proyección de Rayleigh-Ritz de A sobre $\mathcal{K}_k(A, b)$ resulta en: $H_k = Q_k^* A Q_k$

$$H_k = \begin{bmatrix} h_{1,1} & h_{1,2} & h_{1,3} & \dots & h_{1,k} \\ h_{2,1} & h_{2,2} & h_{2,3} & \dots & h_{2,k} \\ 0 & h_{3,2} & h_{3,3} & \dots & h_{3,k} \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \dots & 0 & h_{k,k-1} & h_{k,k} \end{bmatrix}$$

Alternativamente, usando $\tilde{H}_k \in \mathbb{R}^{(k+1)\times k}$:

$$A Q_k = Q_{k+1} \tilde{H}_k$$

Fenómeno de Ruptura (Breakdown)

Si en el paso k el coeficiente subdiagonal se anula ($h_{k+1,k} = 0$):

$$AQ_k = Q_k H_k$$

Implicaciones teóricas y prácticas:

- El subespacio $\mathcal{K}_k(A, b)$ es **estrictamente invariante** bajo A.
- Los k autovalores de H_k coinciden **exactamente** con un subconjunto de autovalores de A.
- En algoritmos como GMRES, esto representa la convergencia exacta de la solución.

Valores de Ritz y Convergencia Espectral

Los autovalores θ_j de la matriz reducida $H_k \in \mathbb{R}^{k \times k}$ se denominan **valores de Ritz**.

- A medida que k aumenta, los valores de Ritz convergen rápidamente hacia los autovalores extremales (de mayor módulo o en los bordes del espectro) de A.
- Si $H_k y^j = \theta_j y^j$, entonces $x^j = Q_k y^j$ es el **vector de Ritz** que aproxima al autovector correspondiente de A.

Casos Particulares y Extensiones

1. **Matriz Simétrica / Hermitiana ($A = A^*$):**
    - H_k se vuelve tridiagonal simétrica.
    - La iteración de Arnoldi se reduce al **Algoritmo de Lanczos**, reduciendo drásticamente el costo computacional por paso.
2. **Resolución de Sistemas $Ax = b$:**
    - Base del método **GMRES** (Generalized Minimal Residual), el cual minimiza $\|b - Ax_k\|_2$ sobre el subespacio de Krylov.
3. **Reinicio Implicito:**
    - En problemas muy grandes, k no puede crecer indefinidamente por restricciones de memoria; se aplican técnicas de reinicio (ej. IRAM / ARPACK).

Convergencia del Proceso de Arnoldi

Análisis Polinomial y Comportamiento Espectral

- **Objetivo:** Comprender la rapidez y el modo en que los valores de Ritz aproximan a los autovalores de la matriz A.
- **Marco Teórico:** La convergencia se analiza mediante la teoría de **aproximación polinomial** sobre el espectro $\Lambda(A)$.
- **Idea Clave:** La iteración de Arnoldi resuelve implícitamente un problema de minimización de norma sobre polinomios mónicos.

El Residuo de un Par de Ritz

Sea (y_k, θ_k) un par propio de la matriz reducida $H_k \in \mathbb{R}^{k\times k}$, es decir, $H_k y_k = \theta_k y_k$ con $\|y_k\|_2 = 1$.

- El **vector de Ritz** correspondiente en $\mathbb{R}^n$ es $u_k = Q_k y_k$ (con $\|u_k\|_2 = 1$).
- Aplicando la relación fundamental $AQ_k = Q_k H_k + h_{k+1,k} q_{k+1} e_k^T$:

$$Au_k - \theta_k u_k = AQ_k y_k - \theta_k Q_k y_k = h_{k+1,k}(e_k^T y_k) q_{k+1}$$

- **Norma del Residuo:**

$$\|Au_k - \theta_k u_k\|_2 = h_{k+1,k} |e_k^T y_k|$$

> **Conclusión:** El par de Ritz es una solución exacta si $h_{k+1,k} = 0$ (ruptura) o si la última componente del autovector y_k es prácticamente nula.

Propiedad de Minimización Polinomial

Sea $\mathcal{P}_k^1$ el conjunto de todos los **polinomios mónicos** de grado k (de la forma $p(z) = z^k + c_{k-1}z^{k-1} + \cdots + c_0$).

Si definimos $p_k(z) = \det(zI_k - H_k)$ como el polinomio característico de H_k:

1. p_k es un polinomio mónico de grado k.
2. Se cumple la propiedad de optimalidad:

$$\|p_k(A)q_1\|_2 = \min_{p \in \mathcal{P}_k^1} \|p(A)q_1\|_2$$

- La iteración de Arnoldi encuentra el polinomio mónico que **minimiza la norma del vector residual** $p(A)q_1$ en el subespacio de Krylov.

Cota de Error mediante Diagonalización

Si la matriz $A \in \mathbb{R}^{n \times n}$ es diagonalizable ($A = X\Lambda X^{-1}$ con $\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$):

- Para cualquier polinomio $p(z)$:

$$p(A) = Xp(\Lambda)X^{-1} = X \operatorname{diag}(p(\lambda_1), \ldots, p(\lambda_n))X^{-1}$$

- Aplicando normas matriciales subordenadas:

$$\|p_k(A)q_1\|_2 \leq \kappa_2(X) \min_{p \in \mathcal{P}_k^1} \max_{\lambda \in \Lambda(A)} |p(\lambda)|$$

donde $\kappa_2(X) = \|X\|_2 \|X^{-1}\|_2$ es el número de condición de la matriz de autovectores.

Convergencia de Autovalores Aislados (Outliers)

El comportamiento de $\min_{p \in \mathcal{P}_k^1} \max_{\lambda \in \Lambda(A)} |p(\lambda)|$ explica qué autovalores se capturan primero:

1. **Autovalores periféricos o aislados:**
    - Si un autovalor λ_1 está alejado del resto del espectro, un polinomio p_k de grado modesto puede colocar una raíz en λ_1 haciendo $p_k(\lambda_1) \approx 0$.
    - Esto cancela la componente asociada a λ_1 rápidamente.
2. **Efecto de "Deflación Implícita":**
    - Una vez que un valor de Ritz converge a λ_1, los pasos posteriores de Arnoldi se enfocan en los autovalores restantes, convergiendo en orden desde el exterior hacia el interior del espectro.

El Papel de los Polinomios de Chebyshev

Cuando los autovalores no aislados de A están contenidos en una región convexa (como una elipse o un intervalo en $\mathbb{R}$):

- La minimización de $|p(\lambda)|$ se resuelve utilizando **Polinomios de Chebyshev** desplazados y escalados.
- La tasa de convergencia depende de la razón del eje mayor al eje menor de la región espectral.

Resumen del Comportamiento de Arnoldi

- **Matrices Normales ($\kappa_2(X) = 1$):** La convergencia está completamente determinada por la distribución geométrica de los autovalores en el plano complejo.
- **Matrices No Normales ($\kappa_2(X) \gg 1$):** El término $\kappa_2(X)$ puede retrasar la

El Método GMRES

Generalized Minimal Residual Method

- **Origen:** Desarrollado por Yousef Saad y Martin H. Schultz (1986).
- **Propósito:** Resolver sistemas de ecuaciones lineales de gran escala $Ax = b$, donde $A \in \mathbb{R}^{n \times n}$ es una matriz no hermitiana (o no simétrica) e invertible.
- **Propiedad Fundamental:** En cada paso k, GMRES encuentra la solución aproximada x_k que **minimiza la norma L_2 del residuo** sobre el subespacio de Krylov.

Formulación del Problema y Subespacio de Krylov

Dado un sistema $Ax = b$ y un vector inicial x_0 con residuo $r_0 = b - Ax_0$:

- Se considera el subespacio de Krylov generado por el residuo inicial:

$$\mathcal{K}_k(A, r_0) = \text{span}\{r_0, Ar_0, A^2 r_0, \ldots, A^{k-1} r_0\}$$

- La solución aproximada en la iteración k se define como:

$$x_k \in x_0 + \mathcal{K}_k(A, r_0)$$

- **Criterio de minimización del residuo:**

$$x_k = \arg \min_{x \in x_0 + \mathcal{K}_k(A, r_0)} \|b - Ax\|_2$$

Reducción mediante la Iteración de Arnoldi

Cualquier vector en el espacio afín se expresa como $x = x_0 + Q_k y$, donde $Q_k \in \mathbb{R}^{n \times k}$ contiene las columnas ortonormales generadas por Arnoldi con $q_1 = r_0/\beta$ y $\beta = \|r_0\|_2$.

- Expresión del vector residuo:

$$r(y) = b - A(x_0 + Q_k y) = r_0 - AQ_k y$$

- Sustituyendo la relación de Arnoldi $AQ_k = Q_{k+1}\tilde{H}_k$, con $\tilde{H}_k \in \mathbb{R}^{(k+1)\times k}$:

$$r(y) = \beta q_1 - Q_{k+1}\tilde{H}_k y = Q_{k+1}(\beta e_1 - \tilde{H}_k y)$$

El Problema de Mínimos Cuadrados Reducido

Puesto que las columnas de Q_{k+1} son ortonormales ($Q_{k+1}^* Q_{k+1} = I_{k+1}$), se preserva la norma L_2:

$$\|b - Ax_k\|_2 = \min_{y \in \mathbb{R}^k} \|\beta e_1 - \tilde{H}_k y\|_2$$

- **Ventaja dimensional:** El problema original de dimensión n se transforma en un problema de mínimos cuadrados de dimensión $(k+1) \times k$, donde $k \ll n$.
- **Elementos:**
  - $\beta = \|r_0\|_2$ (escalar).
  - $e_1 = [1, 0, \ldots, 0]^T \in \mathbb{R}^{k+1}$.
  - $\tilde{H}_k \in \mathbb{R}^{(k+1)\times k}$ es la matriz de Hessenberg reducida.

Resolución Eficiente mediante Rotaciones de Givens

Para resolver $\min_y \|\beta e_1 - \tilde{H}_k y\|_2$ de manera incremental en cada iteración:

1. **Factorización QR acumulativa:** Se aplican rotaciones de Givens $G_1, G_2, \ldots, G_k$ para transformar $\tilde{H}_k$ en una matriz triangular superior R_k (con una última fila nula).
2. **Actualización del vector modificado:**

$$\tilde{g}_k = G_k \ldots G_1(\beta e_1) = \begin{bmatrix} g_k \\ \gamma_{k+1} \end{bmatrix}$$

3. **Cálculo directo del residuo:**

$$\|b - Ax_k\|_2 = |\gamma_{k+1}|$$

   - Permite monitorear la convergencia **sin calcular explícitamente x_k ni resolver el sistema $R_k y_k = g_k$** hasta alcanzar la tolerancia deseada.

GMRES Reiniciado: $GMRES(m)$

Limitación computacional

A medida que k crece:

- El almacenamiento de las columnas de Q_k requiere $O(kn)$ de memoria.
- El costo de ortogonalización escala como $O(k^2 n)$.

Algoritmo $GMRES(m)$

- Se fija un número máximo de pasos m (ej. $m = 30$ o $m = 50$).
- Al alcanzar m iteraciones, se calcula x_m, se reevalúa el residuo $r_m = b - Ax_m$, y se reinicia el proceso tomando $x_0 \leftarrow x_m$.

> **Efecto de estancamiento:** El reinicio pierde la propiedad de optimalidad global sobre el subespacio de Krylov expandido, lo que puede frenar la convergencia si m es demasiado pequeño.