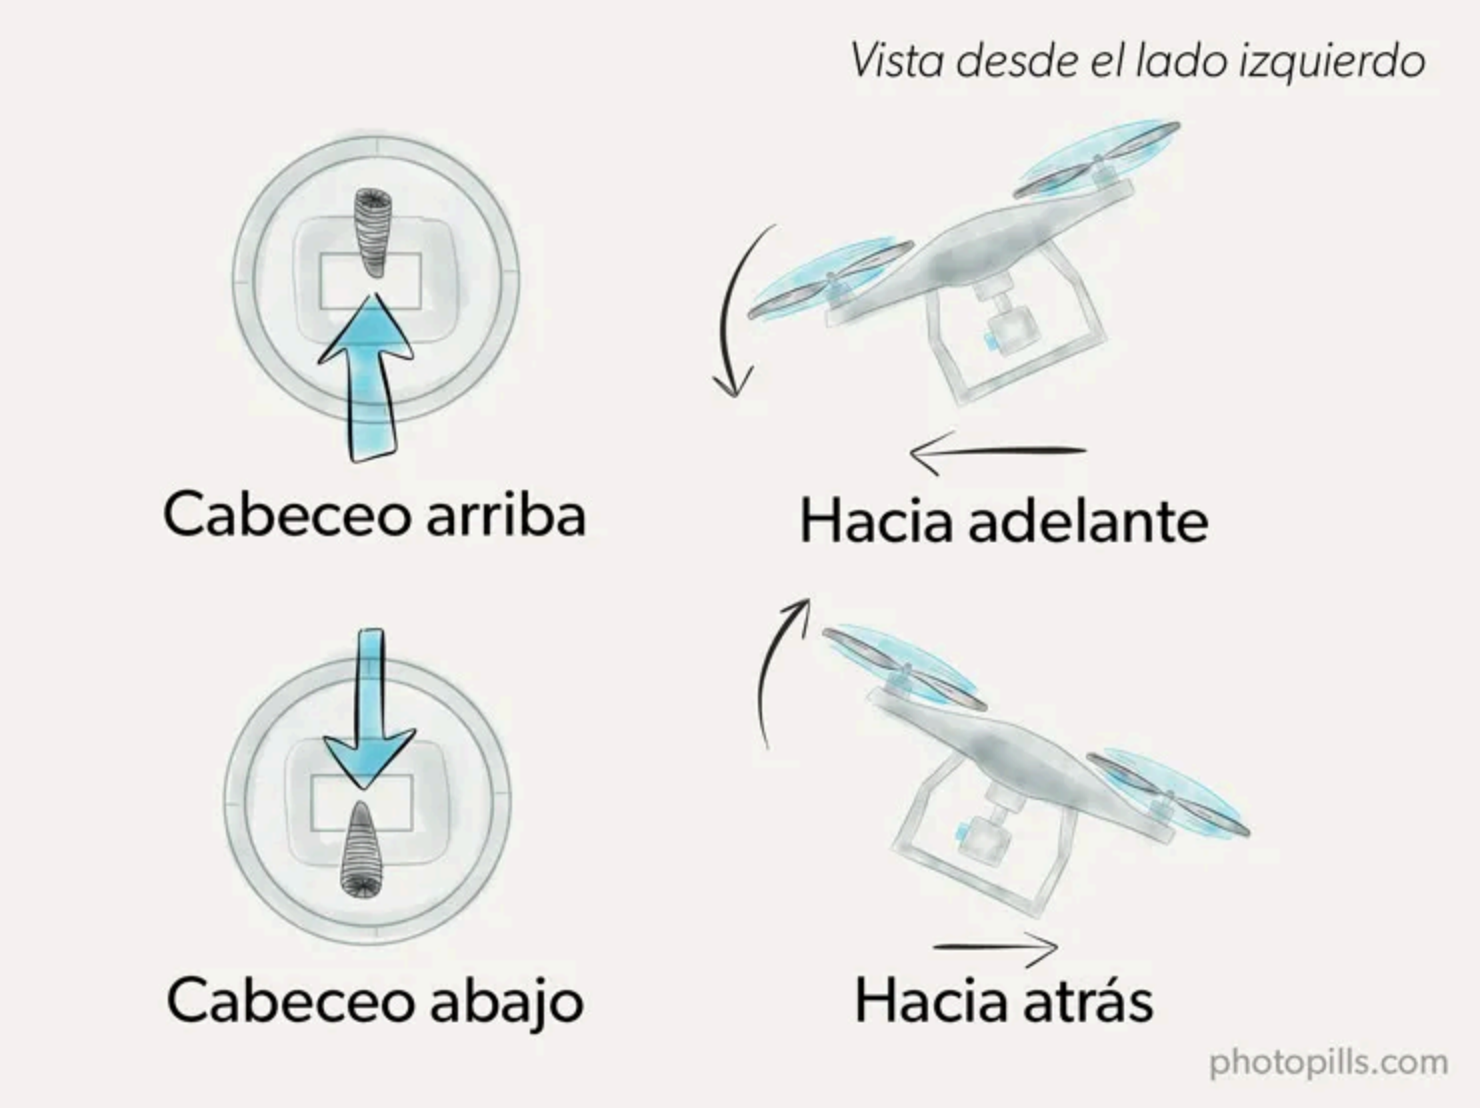
Análisis Numérico II / Álgebra Lineal Numérica

Clase 18: Ecuaciones No Lineales y Minimización



Aplicación: Control de Vuelo Bajo Viento



Sistema No Lineal: Equilibrio de fuerzas para mantener la posición

Para que el dron flote estacionario (derivadas segundas nulas), la sumatoria de fuerzas debe ser nula. Buscamos el Empuje total (T) y la Inclinación (θ):

Eje Horizontal (Balance de viento y empuje)

$$f_1''(T, \theta) = -T \sin(\theta) + F_{drag}(\theta) = 0$$

Eje Vertical (Balance de peso y sustentación):

$$f_2''(T, \theta) = T \cos(\theta) - mg = 0$$

⚠️ Solución analítica imposible: El sistema presenta productos fuertemente acoplados entre T y las funciones trigonométricas de θ.

Vuelo estacionario contra ráfagas horizontales

Cuando un dron intenta mantenerse en una posición fija pero se enfrenta a viento horizontal, debe inclinar su estructura:

- 💨 Inclinación obligatoria contra el viento para generar empuje horizontal.
- 📐 Área aerodinámica variable dependiendo del ángulo de inclinación θ.
- 🌊 Fuerza de arrastre no constante (modelo no lineal).

Modelo de Arrastre Aerodinámico

$$F_{\text{drag}}(\theta) = K_w(\cos(\theta) + \alpha \sin(\theta))$$

(Donde α es la proporción entre el área superior y el área lateral del dron).

Cómo queda nuestro sistema?

$$\begin{cases} f_1''(T,\theta) = -T\sin(\theta) + K_w(\cos(\theta) + \alpha\sin(\theta)) = 0 \\ f_2''(T,\theta) = T\cos(\theta) - mg = 0 \end{cases}$$

- Cómo despejamos T y θ de este sistema? 🤔
- Y cómo podemos resolver la ecuación diferencial cada vez que el dron se inclina o cambia la fuerza de arrastre (muchas veces por segundo)? 🤔🤔🤔

Ecuaciones No Lineales

Sea $F : \mathbb{R}^n \to \mathbb{R}^m$. Buscamos un $x^* \in \mathbb{R}^n$ tal que

$$\begin{cases} f_1(x^*) = 0 \\ f_2(x^*) = 0 \\ \vdots \\ f_m(x^*) = 0 \end{cases}$$

Los problemas no lineales pueden resolverse numéricamente mediante una sucesión de subproblemas lineales que aproximan localmente al problema original.

Definiciones

- Sean $\psi : \mathbb{R}^n \to \mathbb{R}^m$ y $\phi : \mathbb{R}^n \to \mathbb{R}^p$ definidas en un entorno de $x^* \in \mathbb{R}^n$. Diremos que ψ es **dominada** por ϕ en un entorno de x^*, denotado por $\psi(x) = O(\phi(x))$, si existen $\kappa > 0$ y $\delta > 0$ tal que $\|\psi(x)\| \leq \kappa \|\phi(x)\|$ para todo $x \in \mathcal{B}(x^*, \delta)$.
- Diremos que ψ es **despreciable** comparada con ϕ en un entorno de x^*, denotado por $\psi(x) = o(\phi(x))$, si para todo $\varepsilon > 0$ existe $\delta > 0$ tal que $\|\psi(x)\| \leq \varepsilon \|\phi(x)\|$ para todo $x \in \mathcal{B}(x^*, \delta)$.

Método de Newton para Sistemas No Lineales

Si $F : \mathbb{R}^n \to \mathbb{R}^m$ es diferenciable en x^k, entonces su desarrollo de primer orden es:

$$F(x^k) + F'(x^k)(x - x^k) = 0$$

Por lo tanto, podemos construir la siguiente iteración:

$$x^{k+1} = x^k + d_k$$

donde d_k resuelve el sistema lineal $F'(x^k)d_k = -F(x^k)$.

Algoritmo: Método de Newton

Entradas: $F : \mathbb{R}^n \to \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$. **Salida:** x^+ aprox. de x^*.

1. Definir $x = x^0$ y $r = F(x)$, $M = F'(x)$ y $\sigma = \|r\|$.
2. Para $k = 1, \ldots, m$, si $\sigma \leq \epsilon$, ir al paso 3. Sino, definir

$$
\begin{aligned}
&d \quad \text{t.q. } r + Md = 0\\
&x \leftarrow x + d,\\
&r = F(x),\\
&M = F'(x),\\
&\sigma = \|r\|.
\end{aligned}
$$

3. Retornar $x^+ = x$.

Cuál es el garrón más grande acá?

Convergencia y Velocidad de Convergencia

Definiciones: Diremos que una sucesión $\{x^k\}$ converge a x^* con tasa:

- **Lineal** si $\limsup_{k\to\infty} \dfrac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} < 1$,
- **Superlineal** si $\|x^{k+1} - x^*\| = o(\|x^k - x^*\|)$,
- **Cuadrática** si $\|x^{k+1} - x^*\| = O(\|x^k - x^*\|^2)$.

Teorema: Sea $F : \mathbb{R}^n \to \mathbb{R}^n$ continuamente diferenciable en un entorno de x^*, con $F(x^*) = 0$ y $F'(x^*)$ no singular. Entonces existe $\varepsilon > 0$ tal que si $\|x^0 - x^*\| \leq \varepsilon$, la sucesión $\{x^k\}$ generada por el método de Newton converge **superlinealmente** a x^*. Si además $\|F'(\tilde{x}) - F'(x)\| \leq \ell\|\tilde{x} - x\|$ para todo $\tilde{x}, x$ en un entorno de x^*, entonces $\{x^k\}$ converge **cuadráticamente** a x^*.

Método de Newton Truncado (Inexacto)

En problemas de gran dimensión, resolver el sistema lineal de Newton de forma exacta resulta numéricamente costoso.

- Se acepta un paso d_k que satisface $\|F(x_k) + F'(x_k)d_k\| \leq \eta_k \|F(x_k)\|$, donde $\{\eta_k\}$ es la "sucesión forzante".
- Se define $\eta_k = \min\{\gamma, \|F(x_k)\|^\delta\}$ con $\gamma, \delta \in (0, 1)$.
- El sistema lineal $F'(x_k)d = -F(x_k)$ se resuelve inexactamente utilizando GMRES, deteniendo la iteración cuando el residuo alcance la tolerancia $\eta_k \|F(x_k)\|$.
- Si $\eta_0 \leq \delta$ y x_0 está suficientemente cerca de x^*, $\{x_k\}$ converge linealmente; si además $\eta_k \to 0^+$, la convergencia es superlineal.

Algoritmo: Método de Newton Truncado

Entradas: $F : \mathbb{R}^n \to \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$. **Salida:** x^+ aprox. de x^*.

1. Definir $x = x^0$, $\gamma, \delta \in (0, 1)$, $r = F(x)$, $M = F'(x)$ y $\sigma = \|r\|_2$.
2. Para $k = 1, \ldots, m$, si $\sigma \leq \epsilon$, ir al paso 3. Sino, definir

$$\begin{aligned} &\eta = \min\{\gamma, \sigma^\delta\}, \\ &d \leftarrow \mathrm{GMRES}(M, -r, 0, \eta\sigma), \\ &x \leftarrow x + d, \\ &r = F(x), \\ &M = F'(x), \\ &\sigma = \|r\|_2. \end{aligned}$$

3. Retornar $x^+ = x$.

Métodos Cuasi-Newton

- A veces no tendremos la Jacobiana disponible, o será muy costoso calcularla, entonces debemos aproximarla.
- Los métodos cuasi-Newton evitan el cálculo explícito de la Jacobiana $F'(x^k)$ reemplazándola por una matriz de aproximación M_k en el sistema $M_k d^k = -F(x^k)$.
- En las condiciones correctas, estos métodos convergen con tasa superlineal.

Métodos Cuasi-Newton: Ejemplos

- **Diferencias Finitas:** Aproxima cada columna de M_k mediante $M_{*,j} = \frac{1}{h}[F(x + he_j) - F(x)]$ tomando $h = \sqrt{\epsilon_{\text{máq}}}\|x\|$.
- **Ecuación Secante:** Exige que la actualización M_{k+1} satisfaga $M_{k+1}d^k = y^k$, donde $y^k = F(x^{k+1}) - F(x^k)$ y $d^k = x^{k+1} - x^k$.
- **Actualización de Broyden:** Actualización de rango 1 sobre matriz inversa $W_k = M_k^{-1}$, permitiendo calcular $d^k = -W_k F(x^k)$ con producto matriz-vector:

$$W_{k+1} = W_k + \frac{(d^k - W_k y^k)(y^k)^T}{(y^k)^T y^k}$$

Algoritmo: Método de Broyden

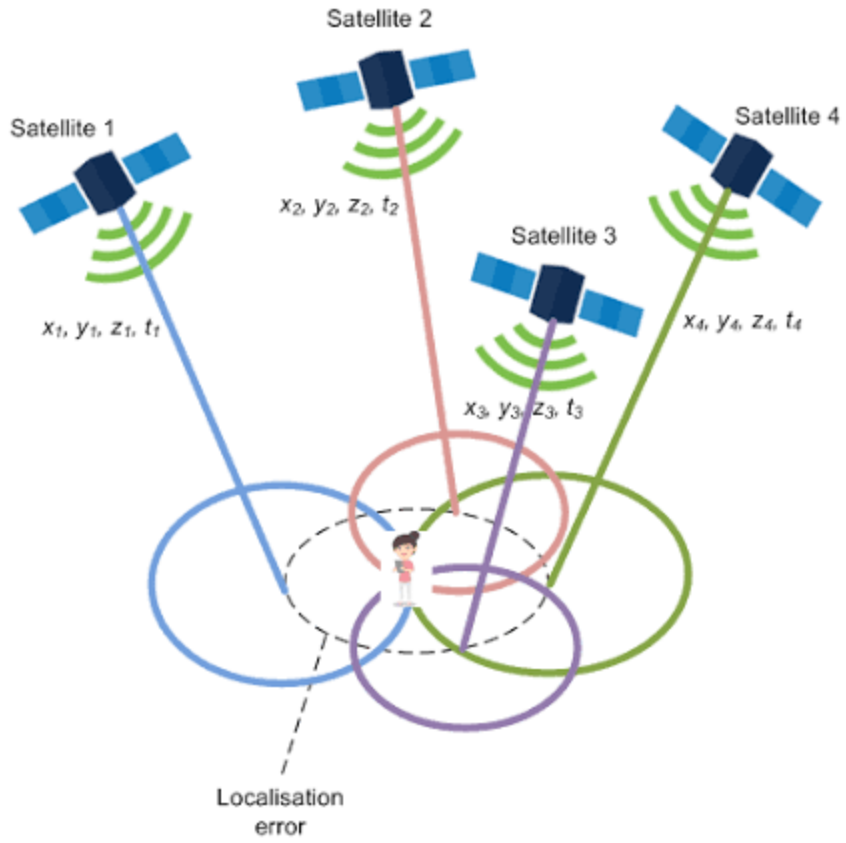
Entradas: $F : \mathbb{R}^n \to \mathbb{R}^n$, $x^0 \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$. **Salida:** x^+ aprox. de x^*.

1. Definir $x = x^0$, obtener $r = F(x)$, $W = I$.
2. Para $k = 1, \ldots, m$, si $\|r\| \leq \epsilon$, ir al paso 3. Sino, definir:

$$
\begin{aligned}
d &= -Wr, \\
x &\leftarrow x + d, \\
r^+ &= F(x), \\
y &= r^+ - r, \\
v &= Wy, \\
W &\leftarrow W + (d - v)y^{\mathrm{T}}/(y^{\mathrm{T}}y), \\
r &= r^+.
\end{aligned}
$$

3. Retornar $x^+ = x$.

Aplicación: Localización por GPS



Aplicación: Localización por GPS (Trilateración)

- Un receptor GPS se comunica con satélites cuyas posiciones (x_i, y_i) son conocidas con precisión para ubicarse.
- Midiendo el tiempo de llegada de la señal, se calcula la distancia d_i a cada satélite.
- Geométricamente, el receptor sabe que está ubicado en una circunferencia de radio d_i centrada en (x_i, y_i).
- Para 3 satélites (en 2D), plantearíamos el siguiente sistema:

$$f_i(x, y) = \sqrt{(x - x_i)^2 + (y - y_i)^2} - d_i = 0 \quad \text{para } i = 1, 2, 3$$

- Este sistema tiene solución?

Cuadrados Mínimos No Lineales

Cuando $F : \mathbb{R}^n \to \mathbb{R}^m$ con $m \neq n$ o la Jacobiana es singular, se reformula el problema como la minimización de la norma del residuo:

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \|F(x)\|_2^2$$

- $f(x)$ es diferenciable si F es diferenciable.

$$\begin{aligned} f(x+h) &= \frac{1}{2} \|F(x+h)\|_2^2 = \frac{1}{2} \|F(x) + F'(x)h + o(\|h\|)\|_2^2 \\ &= \frac{1}{2} \left(\|F(x)\|_2^2 + 2F(x)^{\mathrm{T}} F'(x)h + \|F'(x)h\|_2^2 + o(\|h\|) \right) \\ &= f(x) + \left(F'(x)^{\mathrm{T}} F(x) \right)^{\mathrm{T}} h + o(\|h\|). \end{aligned}$$

Cuadrados Mínimos No Lineales

- El gradiente de $f(x)$ satisface $\nabla f(x) = F'(x)^T F(x)$.
- Suponga que F es diferenciable. Se cumple que $F(x^*) = 0$ si y solo si $\nabla f(x^*) = 0$ y existe d tal que $F(x^*) + F'(x^*)d = 0$.
- La función objetivo $f(x)$ puede presentar minimizadores locales donde $F(x) \neq 0$ ($\nabla f(x^*) = 0$ con $F(x^*) \neq 0$).
- **Proposición:** Sea $F : \mathbb{R}^n \to \mathbb{R}^m$ diferenciable y $f(x) = \frac{1}{2}\|F(x)\|_2^2$. Entonces $F(x^*) = 0$ si y solo si $\nabla f(x^*) = 0$ y existe d tal que $\nabla F(x^*)d = -F(x^*)$.

Marco General de la Minimización No Lineal

Dado un problema con dominio $\mathcal{D} \subset \mathbb{R}^n$, se busca hallar un vector x^* que resuelva:

$$\min_{x \in \mathcal{D}} f(x)$$

Definiciones:

- **Función Objetivo:** La función $f : \mathbb{R}^n \to \mathbb{R}$ a minimizar.
- **Conjunto Factible:** El subconjunto de $\mathbb{R}^n$ donde se busca la solución.
- **Valor Mínimo:** $v_* = \inf_{x \in \mathcal{D}} f(x) \in [-\infty, +\infty]$.
- **Minimizador Global:** $x^* \in \mathcal{D}$ tal que $f(x^*) \leq f(x)$ para todo $x \in \mathcal{D}$.
- **Minimizador Local:** $x^* \in \mathcal{D}$ si existe $\epsilon > 0$ tal que $f(x^*) \leq f(x)$ para todo $x \in \mathcal{B}(x^*, \epsilon) \cap \mathcal{D}$.

Condiciones de Optimalidad

Teorema (Condiciones Necesarias de Optimalidad):

Sea x^* un minimizador local de f en $\mathbb{R}^n$:

1. **Primer orden:** Si f es diferenciable en x^*, entonces $\nabla f(x^*) = 0$.
2. **Segundo orden:** Si f es dos veces diferenciable en x^*, entonces la matriz Hessiana $\nabla^2 f(x^*)$ es semidefinida positiva.

Condiciones de Optimalidad

Definición (Punto Estacionario)

Un punto $x^* \in \mathbb{R}^n$ es un punto estacionario si satisface $\nabla f(x^*) = 0$.

Teorema (Condición Suficiente de Optimalidad)

Si f es dos veces diferenciable en x^*, $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*)$ es **definida positiva**, entonces x^* es un minimizador local de f. Existen $\epsilon > 0$ y $\gamma > 0$ tales que:

$$f(x) \geq f(x^*) + \frac{\gamma}{2}\|x - x^*\|^2, \quad \forall x \in \mathcal{B}(x^*, \epsilon)$$

Esquema General de Búsqueda Lineal

Los algoritmos de **búsqueda lineal** generan una sucesión $x_{k+1} = x_k + \alpha_k d_k$:

1. Dar $x_0 \in \mathbb{R}^n$ y $k = 0$.
2. Si $\|\nabla f(x_k)\| = 0$, detener el proceso (punto estacionario alcanzado).
3. Obtener una **dirección de descenso** $d_k \in \mathbb{R}^n$ tal que $\nabla f(x_k)^T d_k < 0$.
4. Obtener un **tamaño de paso** $\alpha_k > 0$ tal que $f(x_k + \alpha_k d_k) < f(x_k)$.
5. Definir $x_{k+1} = x_k + \alpha_k d_k$, hacer $k \leftarrow k + 1$ y regresar al Paso 1.

Al finalizar el proceso, debe verificarse si la Hessiana $\nabla^2 f(x_{k+1})$ es definida positiva.

Algoritmo: Regla de Armijo (Selección del Paso)

Garantiza un **descenso suficiente** reduciendo el paso inicial $\alpha = 1$ mediante un factor $\beta \in (0, 1)$ hasta satisfacer $\phi(\alpha) \leq \phi_0 + \tau\alpha\phi_0'$, con $\tau \in (0, 1)$.

Entradas: $f : \mathbb{R}^n \to \mathbb{R}$, $x, d \in \mathbb{R}^n$, $\phi_0 = f(x)$, $\phi_0' = \nabla f(x)^T d$, $m \in \mathbb{N}$, $\tau, \beta \in (0, 1)$.
Salida: $x^+ = x + \alpha d$.

1. Definir $\alpha = 1$.
2. Para $k = 1, \ldots, m$, definir $x^+ = x + \alpha d$, $\phi = f(x^+)$.
   Si $\phi \leq \phi_0 + \tau\alpha\phi_0'$, ir al paso 3. Sino, hacer $\alpha \leftarrow \beta\alpha$.
3. Retornar x^+.

En la práctica se utilizan típicamente $\beta = 0.5$ y $\tau = 10^{-4}$.

Algoritmo: Regla de Goldstein (Selección del Paso)

Evita que el paso α sea demasiado pequeño imponiendo una **cota inferior y superior** sobre el incremento funcional mediante el parámetro $\tau \in (0, 1/2)$.

Entradas: $f : \mathbb{R}^n \to \mathbb{R}$, $x, d \in \mathbb{R}^n$, $\phi_0, \phi_0' \in \mathbb{R}$, $m \in \mathbb{N}$, $\tau \in (0, 1/2)$, $\beta \in (0, 1)$, $\rho > 1$.
Salida: $x^+ = x + \alpha d$.

1. Definir $\alpha = 1$, $\alpha_l = 0$ y $\alpha_u = +\infty$.
2. Para $k = 1, \ldots, m$, definir $x^+ = x + \alpha d$, $\phi = f(x^+)$.
   - Si $\phi \leq \phi_0 + \alpha\tau\phi_0'$, ir al paso 2 si $\phi \geq \phi_0 + \alpha(1 - \tau)\phi_0'$ o hacer $\alpha_l = \alpha$ caso contrario. Sino, hacer $\alpha_u = \alpha$.
   - Definir $\alpha = (1 - \beta)\alpha_l + \beta\alpha_u$ si $\alpha_u < +\infty$, o $\rho\alpha_l$ si $\alpha_u = +\infty$.
3. Retornar x^+.

Estrategias Alternativas para la Selección del Paso

Además de las reglas de Armijo y Goldstein, existen otras maneras de determinar α_k:

- **Paso Exacto:** Se toma $\alpha_k = \arg\min_{\alpha \geq 0} f(x_k + \alpha d_k)$. Se utiliza cuando la minimización unidimensional se deduce analíticamente mediante una fórmula cerrada (ej. métodos de proyección).
- **Paso Menguante:** Se predefine una sucesión $\{\alpha_k\}$ que satisface $\alpha_k \to 0^+$ y $\sum_{k=0}^{\infty} \alpha_k = +\infty$. Se aplica si la evaluación funcional de $f(x)$ es muy costosa.
- **Paso Constante:** Se fija $\alpha_k = \alpha > 0$ siempre. Sólo se aconseja en problemas con estructura particular y cotas espectrales conocidas.

Algoritmo: Método de Cauchy para Minimización

Utiliza la dirección de **máximo descenso** $d_k = -\nabla f(x_k)$, que resulta de minimizar $\nabla f(x_k)^T d$ sobre la bola $\|\cdot\|_2 \leq 1$.

Entradas: $f : \mathbb{R}^n \to \mathbb{R}$, $x \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$.
Salida: x^+ aproximación de x^*.

1. Obtener $\phi = f(x)$, $r = \nabla f(x)$ y definir $\sigma = \|r\|_2$.
2. Para $k = 1, \ldots, m$, si $\sigma \leq \epsilon$, ir al paso 3. Sino, definir:
   - x aplicando el **Algoritmo (Armijo)** con $\phi_0 = \phi$ y $\phi'_0 = -\sigma^2$.
   - $\phi = f(x)$, $r = \nabla f(x)$, $\sigma = \|r\|_2$.
3. Retornar $x^+ = x$.

Algoritmo: Método de Newton para Minimización

Resuelve el sistema de segundo orden $\nabla^2 f(x_k)d_k = -\nabla f(x_k)$ derivado de la condición de estacionariedad $\nabla f(x) = 0$.

Entradas: $f : \mathbb{R}^n \to \mathbb{R}$, $x \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$. **Salida:** x^+ aproximación de x^*.

1. Obtener $\phi = f(x)$, $r = \nabla f(x)$ y $H = \nabla^2 f(x)$.
2. Para $k = 1, \ldots, m$, si $\|r\|_2 \leq \epsilon$, ir al paso 3. Sino, definir:
    - d tal que $r + Hd = 0$ resolviendo el sistema SDP mediante Cholesky.
    - x aplicando Armijo con $\phi_0 = \phi$ y $\phi'_0 = r^T d$.
    - $\phi = f(x)$, $r = \nabla f(x)$, $H = \nabla^2 f(x)$.
3. Retornar $x^+ = x$.

Modificaciones del Método de Newton

Cuando f no es estrictamente convexa, la Hessiana $\nabla^2 f(x_k)$ puede ser indefinida o singular. Se aplican modificaciones para garantizar la definición positiva:

- **Cholesky Modificado:** Reemplaza los pivotes $G_{ii} \leq \epsilon_0$ por $\epsilon_1 > \epsilon_0 \geq 0$ antes de calcular la raíz cuadrada, asegurando $G^T G = \nabla^2 f(x_k) + E_k > 0$.
- **Dirección de Gauss-Newton:** Para problemas de cuadrados mínimos no lineales $f(x) = \frac{1}{2}\|F(x)\|_2^2$, se aproxima la Hessiana omitiendo las derivadas de segundo orden: $H_k = F'(x_k)^T F'(x_k) \geq 0$.
- **Método de Levenberg-Marquardt:** Regulariza la matriz de Gauss-Newton sumando un término diagonal $\gamma_k I$ con $\gamma_k > 0$: $H_k = F'(x_k)^T F'(x_k) + \gamma_k I > 0$.

Algoritmo: Método BFGS para Minimización

Implementa la actualización secante de rango 2 para la inversa de la Hessiana $W_k \approx (\nabla^2 f(x_k))^{-1}$, permitiendo calcular $d = -Wr$ con un producto matriz-vector.

Entradas: $f : \mathbb{R}^n \to \mathbb{R}$, $x \in \mathbb{R}^n$, $\epsilon > 0$ y $m \in \mathbb{N}$.

1. Obtener $\phi = f(x)$, $r = \nabla f(x)$, definir $W = I$ y $x^+ = x$.
2. Para $k = 1, \ldots, m$, si $\|r\|_2 \leq \epsilon$, ir al paso 2. Sino, definir:
   - $d = -Wr$, x^+ aplicando Armijo con $\phi_0 = f(x)$ y $\phi_0' = r^T d$.
   - $\phi = f(x^+)$, $r^+ = \nabla f(x^+)$, $y = r^+ - r$, $v = x^+ - x$, $w = Wy$.
   - $\gamma = y^T v$, $\tau = y^T w$, $p = v/\gamma - w/\tau$.
   - $W = W + \frac{vv^T}{\gamma} - \frac{ww^T}{\tau} + \tau pp^T$, $x = x^+$, $r = r^+$.
3. Retornar x^+.

Convergencia del Método de Búsqueda Lineal

- **Peligro de las Búsquedas Unidimensionales:**
  Dada $f(x_1, x_2) = (x_2 - px_1^2)(x_2 - qx_1^2)$ con $0 < p < q$, el origen $(0, 0)$ es un minimizador local a lo largo de **toda recta** que pasa por él, pero **no es un minimizador local en** $\mathbb{R}^2$.
- **Teorema:** Sea f continuamente diferenciable y $\{x_k\}$ generada por un método de búsqueda lineal con paso de Armijo y dirección que satisface $\nabla f(x_k)^T d_k \leq -\gamma \|\nabla f(x_k)\|^q$ con $\gamma, q > 0$. Entonces todo punto límite x^* de la sucesión $\{x_k\}$ es un **punto estacionario** ($\nabla f(x^*) = 0$).